Exemplo motivacional

Prof. Eduardo Vargas Ferreira

Curso de Especialização em Data Science & Big Data Universidade Federal do Paraná

16 de março de 2018

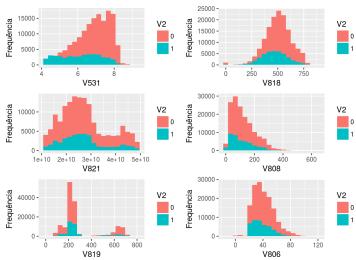
Machine Learning for medicine

 O problema apresentado se refere a um estudo sobre o tempo até a cura de uma doença.



- Acompanhou-se 145340 pacientes durante 24 meses. Todos recebendo o mesmo tipo de tratamento;
- O interesse é prever qual paciente responderá positivamente a essa intervenção e a velocidade de cura.





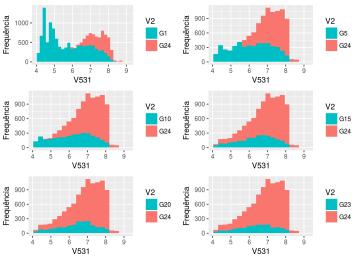


Pense um passo a frente

 A análise não pode parar no gráfico! Você deve extrair algo adicional que a máquina não é capaz de fazer.

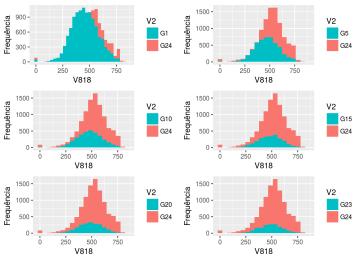




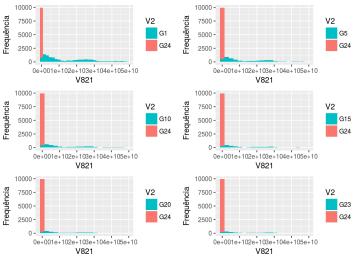




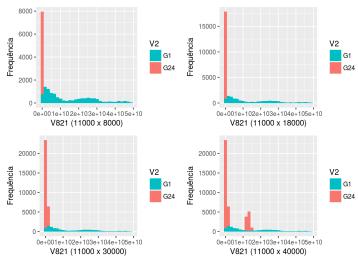
5/32



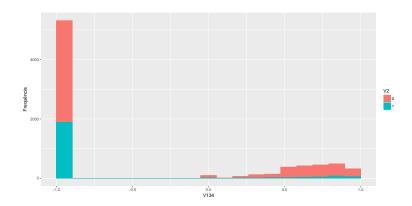




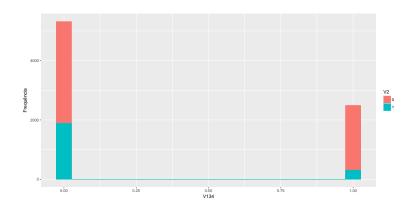




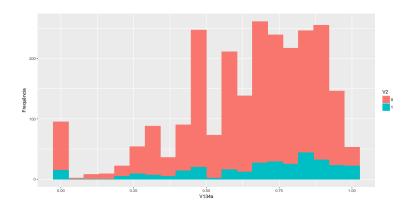




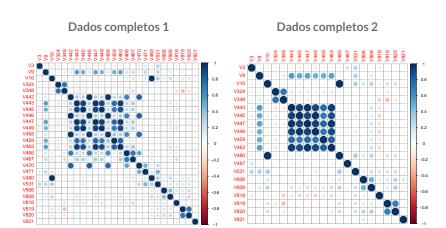














Predição versus Inferência

Data Modeling Culture

- Domina a comunidade estatística:
- O principal objetivo está na interpretação dos parâmetros;
- ► Testar suposições é fundamental.

Algorithmic Modeling Culture

- Domina a comunidade de Machine Learning;
- O modelo é utilizado para criar bons algoritmos preditivos;
- ▶ Interpretamos os resultados, mas esse em geral não é o foco.

L. Breiman. Statistical modeling: The two cultures. Statistical Science, 16(3):199-231, 2001



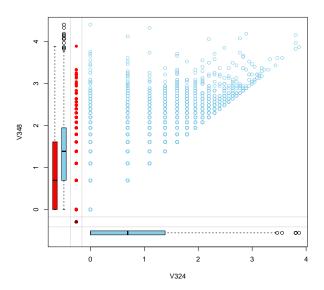
Dados faltantes

- Missing completely at random: quando a probabilidade dos dados faltantes é a mesma entre as observações, p ex.:
 - ▶ Dados perdidos por um *backup* incorreto;
- Missing at random: quando os dados faltantes variam de acordo com outras variáveis, p. ex.:
 - Missing sobre idade pode ser diferente entre mulheres e homens;
- Missing not at random: quando a probabilidade de missing está relacionada com o missing, p. ex.,:
 - Dependendo da renda do cliente, é mais provável que ele não responda sobre a renda;
 - Indivíduo não comparece ao teste de droga, porque a utilizou na noite anterior.

Tratamento dos dados faltantes

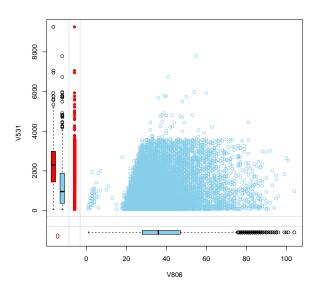
- ▶ **Deletar:** utilizado quando a natureza do "missing" é **completely at random**.
 - Podemos eliminar a linha inteira. É uma abordagem simples, mas retira poder dos dados, devido à redução do tamanho da amostra;
 - Ou utilizar os dados completos, de acordo somente com as variáveis de interesse.
- Imputação: utilizado quando trata-se de missing at random ou missing not at random.
 - Média, mediana, moda.
 - Modelo preditivo;
 - ► KNN





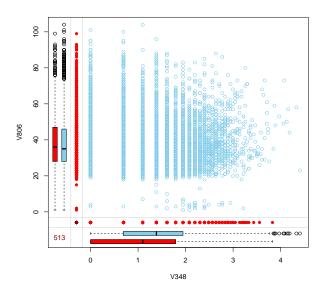


Eduardo Vargas Ferreira Exemplo motivacional 16/32



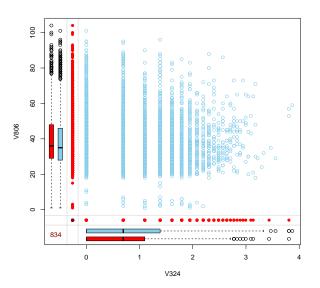


Eduardo Vargas Ferreira Exemplo motivacional 17/32

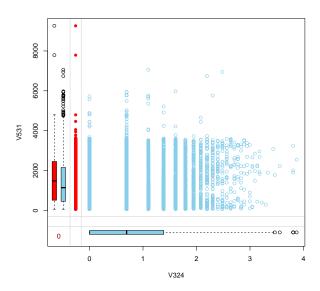




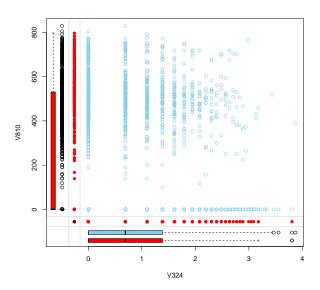
Eduardo Vargas Ferreira Exemplo motivacional 18/32





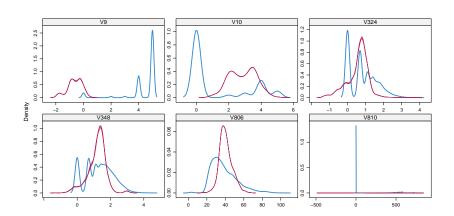




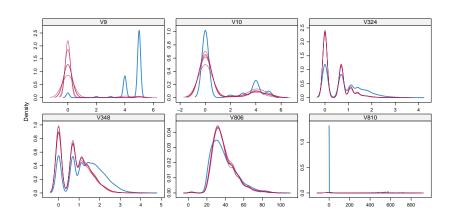




Eduardo Vargas Ferreira Exemplo motivacional 21/32







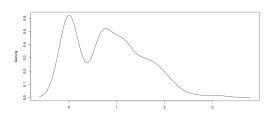


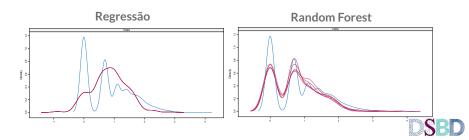
Pergunta

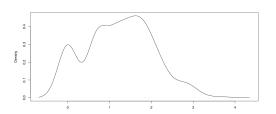
- Você confiaria em modelos estatísticos produzidos a partir da eliminação dos dados faltantes? E a partir da imputação dos dados faltantes?
- Você confiaria em modelo estatístico cujos dados possuem outliers?

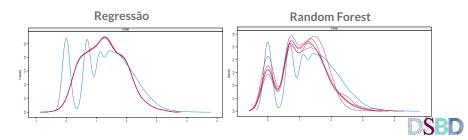


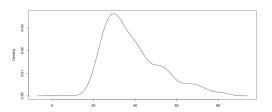
► Em probabilidade é que desenvolvemos as percepções sobre os dados!

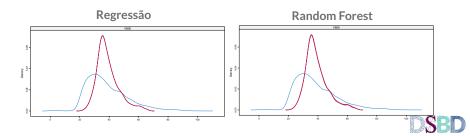




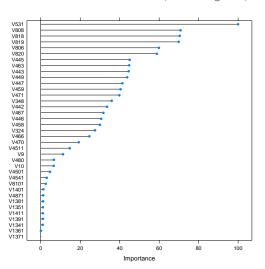








SMOTE: 20% sim e 80% não (dados originais)



Confusion Matrix and Statistics

Reference
Prediction 0 1
0 4168 890
1 142 238

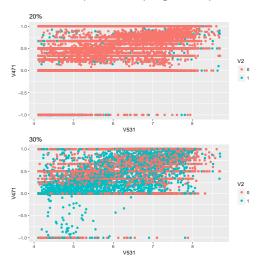
Accuracy: 0.8102 95% CI: (0.79, 0.82)

Sensitivity: 0.9671 Specificity: 0.2110 Pos Pred Value: 0.8240 Neg Pred Value: 0.6263



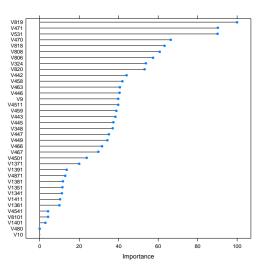
SMOTE

► SMOTE: Synthetic Minority Over-sampling Technique





SMOTE: 25% sim e 75% não



Confusion Matrix and Statistics

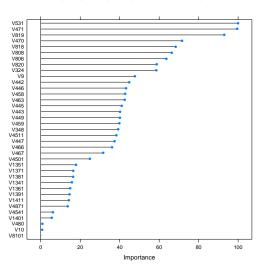
Reference Prediction 0 1 0 4258 729 1 52 399

Accuracy: 0.8564 95% CI: (0.84, 0.86)

Sensitivity: 0.9879 Specificity: 0.3537 Pos Pred Value: 0.8538 Neg Pred Value: 0.8847



SMOTE: 30% sim e 70% não



Confusion Matrix and Statistics

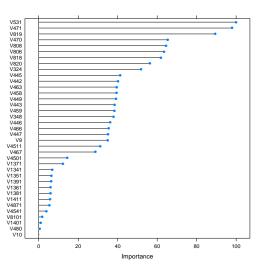
Reference Prediction 0 1 0 4189 612 1 121 516

Accuracy: 0.8652 95% CI: (0.85, 0.87)

Sensitivity: 0.9719 Specificity: 0.4574 Pos Pred Value: 0.8725 Neg Pred Value: 0.8100



SMOTF: 50% sim e 50% não



Confusion Matrix and Statistics

Reference
Prediction 0 1
0 3861 368
1 449 760

Accuracy: 0.8498 95% CI: (0.84, 0.85)

Sensitivity: 0.8958 Specificity: 0.6738 Pos Pred Value: 0.9130 Neg Pred Value: 0.6286

