

# Introdução ao Cálculo Diferencial Integral para Ciência de Dados

Prof. Wagner Hugo Bonat

Curso de Especialização em  
Data Science & Big Data  
Universidade Federal do Paraná

6 de abril de 2018



# Conteúdo

# Conteúdo

1. Funções, limites e continuidade.
2. Derivada
  - 2.1 Definição e aplicações;
  - 2.2 Regra da cadeia;
  - 2.3 Máximos e mínimos.
  - 2.4 Funções de duas ou mais variáveis independentes.
  - 2.5 Gradiente e Hessiano.
  - 2.6 Expansão em Série de Taylor.
3. Integrais
  - 3.1 Definição;
  - 3.2 Soma de Riemann;
  - 3.3 Teorema fundamental do cálculo;
  - 3.4 Propriedades;
  - 3.5 Regras de integração.



# Funções, limites e continuidade.

# Funções

- ▶ Definição 1 - Uma **função** escrita como  $y = f(x)$  associa um número  $y$  a cada valor de  $x$ .
- ▶  $x$  é chamada de variável **independente**.
- ▶ **Domínio de  $f(x)$**  é a faixa de valores que  $x$  pode assumir.
- ▶  $y$  é chamada de variável **dependente**.
- ▶ **Imagem de  $f(x)$**  é a faixa de valores que  $y$  pode assumir.
- ▶ Resumindo temos,

$$\begin{array}{ccc} x \in D & \xrightarrow{\quad} & f(x) \xrightarrow{\quad} y \in I \\ \text{Independente} & & \text{Dependente} \end{array}$$


- ▶ O **domínio** e **imagem** de uma função são intervalos.
- ▶ Tipos de intervalos:
  - ▶ Intervalo aberto **não contêm** as extremidades: Notação  $(a, b)$ .
  - ▶ Intervalo fechado **contêm** as extremidades: Notação  $[a, b]$ .

# Exemplo

- Considere a função  $y = x^2$

```
fx = function(x) {  
  out <- x^2  
  return(out)  
}
```

- Gráfico da função



# Funções parametrizadas


- ▶ Definição 2 - **Parâmetro** é uma quantidade conhecida que indexa ou parametriza uma determinada função.
- ▶ Em geral os parâmetros mudam o comportamento da função e descrevem quantidades de interesse.
- ▶ Notação:  $y = f(x; \theta)$ , onde  $\theta$  denota o parâmetro.
- ▶ O conjunto de valores que  $\theta$  pode assumir é chamado de espaço paramétrico. Notação  $\theta \in \Theta$ .

# Exemplo: Função parametrizada

- ▶ Exemplo:  $y = (x - \theta)^2$

```
fx = function(x, theta) {  
  out <- (x - theta)^2  
  return(out)  
}
```

- ▶ Gráfico da função.





# Funções com vários parâmetros

- ▶ Em geral uma função pode ter vários parâmetros.
- ▶ O ideal é que cada parâmetro controle um aspecto da função.
- ▶ Exemplo:  $y = f(x; \theta_1, \theta_2)$  ou mais geral  $y = f(x; \theta)$ , onde  $\theta$  é um vetor de parâmetros.
- ▶ Função com dois parâmetros:


$$y = \frac{(x - \theta_1)^2}{\theta_2}.$$

# Funções com múltiplos parâmetros

## ► Função em R.

```
fx = function(x, theta) {  
  out <- ((x - theta[1])^2)/theta[2]  
  return(out)  
}
```

## ► Gráfico da função para diferentes valores dos parâmetros.



# Limite de uma função

- Definição 3 - Se uma função  $f(x)$  se aproxima de um número  $L$  conforme  $x$  tende a um número  $a$  vindo da direita ou da esquerda, dizemos que o limite de  $f(x)$  tende a  $L$  quando  $x$  tende a  $a$ .

- Notação


$$\lim_{x \rightarrow a} f(x) = f(a) = L.$$

- O limite pode não existir.
- Se o limite de uma função existe ele é único.

# Limite de funções - Exemplo 1

- Considere o limite

$$\lim_{x \rightarrow 1} (x + 1) = 2.$$



## Limite de funções - Exemplo 2


- Considere o limite

$$\lim_{x \rightarrow 1} \frac{x^2 - 1}{x - 1} = ?$$

```
fx <- function(x) {  
  out <- (x^2 - 1)/(x - 1)  
  return(out)  
}  
fx(x = 1)  
## [1] NaN
```

## Limite de funções - Exemplo 2

- Graficamente temos



## Limite de funções - Exemplo 2

- Note que

$$\lim_{x \rightarrow 1} \frac{x^2 - 1}{x - 1} = \lim_{x \rightarrow 1} \frac{(x + 1)(x - 1)}{x - 1} = \lim_{x \rightarrow 1} (x + 1) = 2.$$

- **Definição intuitiva:** O limite de uma função é o valor que achamos natural para ela em um determinado ponto.

# Continuidade de uma função


- ▶ Definição 4 - Dizemos que uma função é **contínua** em  $x = a$  se três condições forem satisfeitas:  $f(a)$  existe,  $\lim_{x \rightarrow a} f(x)$  existe e  $\lim_{x \rightarrow a} f(x) = f(a)$ .
- ▶ Continuidade significa que pequenas variações na variável independente levam a pequenas variações na variável dependente.
- ▶ **Teorema do valor intermediário:** Se a função  $f(x)$  é contínua no intervalo fechado  $[a, b]$ , então existe pelo menos um número  $c$  em  $[a, b]$  tal que  $f(c) = M$ .
- ▶ Implicação: Se  $f(x)$  é contínua seu gráfico não contém salto vertical.
- ▶ Em geral podemos pensar em funções contínuas como sendo funções suaves.



## Exemplo - Função não contínua

- Considere a função não contínua em 0.

$$\lim_{x \rightarrow 0} \frac{|x|}{x} = \begin{cases} -1 & x < 0 \\ 1 & x > 0. \end{cases}$$





# Derivadas

# Derivada de uma função

- Definição 5 - Derivada ordinária, derivada primeira, ou simplesmente, derivada de uma função  $y = f(x)$  em um ponto  $x = a$  no domínio de  $f$  é representada por  $\frac{dy}{dx}$ ,  $y'$ ,  $\frac{df}{dx}$  ou  $f'(a)$  é o valor

$$\frac{dy}{dx}|_{x=a} = f'(a) = \lim_{h \rightarrow 0} \frac{f(a+h) - f(a)}{h}.$$

## Exemplo: Derivada de uma função

- Obtenha a derivada de  $f(x) = -x^2$ .

$$\begin{aligned}f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\&= \lim_{h \rightarrow 0} \frac{-(x+h)^2 - (-x^2)}{h} \\&= \lim_{h \rightarrow 0} \frac{-(x^2 + 2xh + h^2) + x^2}{h} \\&= \lim_{h \rightarrow 0} \frac{-x^2 - 2xh - h^2}{h} = \frac{-2xh - h^2}{h} \\&= \lim_{h \rightarrow 0} -2x - h = -2x.\end{aligned}$$

# Interpretação da derivada

- ▶ Taxa de mudança instantânea.
- ▶ No limite quando  $x \rightarrow a$  a derivada é a reta tangente ao ponto  $(a, f(a))$ .
- ▶ A reta tangente ao ponto  $a$  tem equação dada por  $y - f(a) = f'(a)(x - a)$ .
- ▶ Exemplo: Obtenha a reta tangente a  $f(x)$  nos pontos  $x = 2$  e  $x = -2$ .
- ▶ Temos  $f(x = 2) = -4$  e  $f'(x = 2) = -4$ , assim

$$y - f(x = 2) = f'(x = 2)(x - 2)$$

$$y - (-4) = -4(x - 2)$$

$$y + 4 = -4x + 8$$


$$y = 4 - 4x$$

# Exemplo - Reta tangente a $f(x)$

## ► $f(x)$ e $f'(x)$ .

```
fx <- function(x) {  
  out <- - x^2  
  return(out)  
}  
  
f_prime <- function(x) {  
  out <- -2*x  
  return(out)  
}  
  
# Equação da reta y = a + b*x  
intercept = (fx(x = 2) - f_prime(x = 2)*2)  
intercept  
  
## [1] 4  
  
slope <- f_prime(x = 2)  
slope  
  
## [1] -4
```

## Exemplo - Reta tangente a $f(x)$



# Regras de derivação

- Seja  $n \neq 0$  um natural. São válidas as fórmulas de derivação:

1. Se  $f(x) = c$  então  $f'(x) = 0$ .
2. Se  $f(x) = x^n$  então  $f'(x) = nx^{n-1}$ .
3. Se  $f(x) = x^{-n}$  então  $f'(x) = -nx^{-n-1}$ .
4. Se  $f(x) = x^{1/n}$  então  $f'(x) = \frac{1}{n}x^{\frac{1}{n}-1}$ .

- Derivada de funções especiais.

1. Se  $f(x) = \exp(x)$  então  $f'(x) = \exp(x)$ .
2. Se  $f(x) = \ln(x)$  então  $f'(x) = \frac{1}{x}, x > 0$ .

- Sejam  $f(x)$  e  $g(x)$  deriváveis em  $x$  e seja  $c$  uma constante. Então as funções  $f(x) + g(x)$ ,  $cf(x)$  e  $f(x) \cdot g(x)$  são deriváveis em  $x$  e têm-se

1.  $(f + g)' = f'(x) + g'(x)$ .
2.  $(cf)'(x) = cf'(x)$ .
3.  $(f \cdot g)'(x) = f'(x)g(x) + f(x)g'(x)$ .



# Regras de derivação

- ▶ Regra da cadeia: Sejam  $y = f(x)$  e  $x = g(t)$  duas funções deriváveis, com  $I \in D_f$ . A função composta  $h(t) = f(g(t))$  é derivável, sendo

$$h'(t) = f'(g(t))g'(t), t \in D_g.$$

- ▶ Existe uma infinidade de fórmulas de derivação.
- ▶ Na prática é comum usar um software de matemática simbólica como o wxMaxima.
- ▶ Em R as funções `deriv()` e `deriv3()`.
- ▶ Exemplos.

# Por que derivadas são importantes?

- ▶ Derivada é a inclinação (slope) da reta tangente à curva  $y = f(x)$ .
- ▶ **Obtenção de máximo ou mínimo de uma função (fundamental !!!).**
- ▶ O **máximo** de uma função  $f(x)$  é o valor  $x_n$  tal que,  $f(x_n) \geq f(x), \forall x \in D$ .
- ▶ O **mínimo** de uma função  $f(x)$  é o valor  $x_1$  tal que,  $f(x_1) \leq f(x), \forall x \in D$ .

# Problema: Redução de dados

- ▶ Suponha que temos um conjunto de observações  $y_i$  para  $i = 1, \dots, n$ . Queremos resumir a informação contida em  $y_i$  em um único número, digamos  $\mu$ .
- ▶ Problema: Como encontrar  $\mu$ ?
- ▶ Solução: Encontrar o valor  $\mu$ , tal que  $f(\mu) = \sum_{i=1}^n (y_i - \mu)^2$ , seja a menor possível.
- ▶ Note que uma vez que temos os números observados  $y_i$  a única quantidade desconhecida é  $\mu$ .
- ▶ Note que  $\mu$  é o parâmetro da nossa função.
- ▶ A função  $f(\mu)$  mede o quanto **perdemos** em representar  $y_i$  apenas usando  $\mu$ .
- ▶ Funções perda muito populares são a **perda quadrática**, **perda absoluta**, **minmax** e a **cross entropia**.

# Exemplo: Redução de dados

## ► Funções em R.

```
set.seed(123)
y <- rpois(10, 10)

fmu <- function(mu, y) {
  out <- sum((y - mu)^2)
  return(out)
}


fmu <- Vectorize(fmu, "mu")
fmu(mu = c(10, 12), y = y)

## [1] 117 161

f_prime <- function(mu, y) {
  out <- -2*sum(y-mu)
  return(out)
}
```


# Exemplo: Redução de dados

- Graficamente, temos



## Exemplo: Redução de dados

- Note que o **melhor** resumo dos dados de um número, corresponde ao ponto de mínimo da função  $f(\mu) = \sum_{i=1}^n (y_i - \mu)^2$ .
- Como o mínimo está relacionado com a derivada de  $f(\mu)$ ?



## Exemplo: Redução de dados

- ▶ No ponto de mínimo/máximo a inclinação da reta tangente a  $f(\mu)$  é zero.
- ▶ Denote por  $\hat{\mu}$  o ponto de mínimo/máximo de  $f(\mu)$ , então  $f(\hat{\mu}) = 0$ .
- ▶ Assim, temos (regra da cadeia!!)

$$\begin{aligned}f'(\mu) &= 2 \sum_{i=1}^n (y_i - \mu) \frac{d}{d\mu} (y_i - \mu) \\&= 2 \sum_{i=1}^n (y_i - \mu)(-1) = -2 \sum_{i=1}^n (y_i - \mu).\end{aligned}$$

## Exemplo: Redução de dados

- Agora precisamos achar o ponto  $\hat{\mu}$  tal que  $f(\hat{\mu}) = 0$ .

$$f'(\hat{\mu}) = 0$$

$$-2 \sum_{i=1}^n (y_i - \hat{\mu}) = 0$$

$$-\sum_{i=1}^n y_i + n\hat{\mu} = 0$$

$$n\hat{\mu} = \sum_{i=1}^n y_i$$

$$\hat{\mu} = \frac{\sum_{i=1}^n y_i}{n}.$$



# Máximos e mínimos

- ▶ Sejam  $f(x)$  uma função que admite segunda derivada no intervalo aberto  $I$  e  $x \in I$ .
  1.  $f'(x) = 0$  e  $f''(x) > 0$  é ponto de mínimo local.
  2.  $f'(x) = 0$  e  $f''(x) < 0$  é ponto de máximo local.
- ▶  $f''(x)$  denota a segunda derivada de  $f(x)$ , i.e.  $\frac{\partial^2 f(x)}{\partial x^2}$ .
- ▶ Em geral em estatística e técnicas padrões de *machine learning* a função objetivo/perda é criada para ter apenas um ponto de mínimo/máximo.
- ▶ Em situações patológicas, tais como falta de identificabilidade a função pode ter mais de um mínimo/máximo.
- ▶ Exemplos.

# Funções de duas ou mais variáveis independentes

- ▶ Em geral uma função possui apenas uma variável dependente.
- ▶ Porém, pode ter duas ou mais variáveis independentes.
- ▶ Exemplo 1:

$$z = f(x, y) = \frac{x^2}{2^2} + \frac{y^2}{3^2}.$$

- ▶ Exemplo 2: Sejam  $y_i$  e  $x_i$  quantidades observadas. A equação da reta que relaciona  $x$  e  $y$  é dada por

$$y_i = f(\beta_0, \beta_1; x_i) = \beta_0 + \beta_1 x_i.$$

# Derivadas parciais

- Para uma função  $z = f(x, y)$ , a derivada parcial de  $f$  em relação a  $x$  é representada por  $\frac{\partial f}{\partial x}$ , e é definida por

$$\frac{\partial f}{\partial x} = \lim_{h \rightarrow 0} \frac{f(x + h, y) - f(x, y)}{h},$$

desde que o limite exista.

- De forma similar, a derivada parcial de  $f(x, y)$  em relação a  $y$  é representada por

$$\frac{\partial f}{\partial y} = \lim_{h \rightarrow 0} \frac{f(x, y + h) - f(x, y)}{h}.$$

- De forma geral,  $\frac{\partial f(x)}{\partial x}$  é obtida derivando  $f(x)$  considerando  $y$  fixo e vice-versa.

# Gradiente e Hessiano

- ▶ O gradiente de uma função  $f(x, y)$  é o vetor composto pelas derivadas primeira de  $f(x, y)$  em relação a  $x$  e  $y$ , i.e.

$$\nabla f(x, y) = \left( \frac{\partial f(x, y)}{\partial x}, \frac{\partial f(x, y)}{\partial y} \right).$$

- ▶ O Hessiano de uma função  $f(x, y)$  é a matrix

$$\mathbf{H} = \begin{pmatrix} \frac{\partial^2 f(x, y)}{\partial x^2} & \frac{\partial^2 f(x, y)}{\partial x \partial y} \\ \frac{\partial^2 f(x, y)}{\partial y \partial x} & \frac{\partial^2 f(x, y)}{\partial y^2} \end{pmatrix}.$$

- ▶ As definições se estendem naturalmente para mais de duas variáveis.
- ▶ Vamos revisar as ideias de vetores e matrizes (álgebra linear).

# Expansão de funções em Série de Taylor

- ▶ Aproximação por Série de Taylor é fundamental em estatística e métodos numéricos.
- ▶ É uma forma simples de obter o valor aproximado de uma função perto de um ponto conhecido  $x_0$ .
- ▶ Dada uma função  $f(x)$  derivável  $(n + 1)$  vezes em um intervalo contendo um ponto  $x = x_0$ , temos

$$\begin{aligned} f(x) = & f(x_0) + (x - x_0) \frac{df(x)}{dx} \Big|_{x=x_0} + \frac{(x - x_0)^2}{2!} \frac{d^2f(x)}{dx^2} \Big|_{x=x_0} + \\ & \dots + \frac{(x - x_0)^n}{n!} \frac{d^nf(x)}{dx^n} \Big|_{x=x_0} + R_n(x). \end{aligned}$$

- ▶ Aproximação similar é possível para funções com duas ou mais variáveis.

## Exemplo - Regressão linear simples

- ▶ Seja  $y_i (i = 1, \dots, n)$  observações de alguma variável de interesse.
- ▶ Seja  $x_i$  uma outra variável que queremos relacionar com  $y_i$  através de uma reta, i.e.

$$y_i = \beta_0 + \beta_1 x_i.$$


- ▶ Problema: Encontrar  $\beta_0$  e  $\beta_1$  tal que

$$SQ = f(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2,$$

seja a menor possível.

# Exemplo - Regressão linear simples

- Graficamente, temos



# Como encontrar $\beta_0$ e $\beta_1$ que minimizam a SQ?

## ► Abordagem 1

1. Obter o vetor gradiente

$$\nabla f(\beta_0, \beta_1) = \left( \frac{\partial f(\beta_0, \beta_1)}{\partial \beta_0}, \frac{\partial f(\beta_0, \beta_1)}{\partial \beta_1} \right).$$

2. Encontrar  $\hat{\beta}_0$  e  $\hat{\beta}_1$  tal que

$$\nabla f(\hat{\beta}_0, \hat{\beta}_1) = \mathbf{0}.$$

- Abordagem 2 - Obter a derivada analiticamente, mas resolver o sistema numericamente.
- Abordagem 3 - Obter a derivada e resolver o sistema numericamente.
- Abordagem 4 - Usar um algoritmo de otimização genérico.



# Vetor gradiente

- ▶ Chame  $y_i - (\beta_0 + \beta_1 x_i) = \epsilon_i$ .
- ▶ Chame  $\beta_0 + \beta_1 x_i = \mu_i$ .
- ▶ Assim,

$$\nabla f(\beta_0, \beta_1) = \left( \frac{\partial f(\beta_0, \beta_1)}{\partial \epsilon_i} \frac{\partial \epsilon_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \beta_0}, \frac{\partial f(\beta_0, \beta_1)}{\partial \epsilon_i} \frac{\partial \epsilon_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \beta_1} \right).$$

onde

$$\frac{\partial f(\beta_0, \beta_1)}{\partial \epsilon_i} = \frac{\partial}{\partial \epsilon_i} \sum_{i=1}^n \epsilon_i^2 = 2 \sum_{i=1}^n \epsilon_i.$$

$$\frac{\partial \epsilon_i}{\partial \mu_i} = \frac{\partial}{\partial \mu_i} (y_i - \mu_i) = -1.$$

$$\frac{\partial \mu_i}{\partial \beta_0} = \frac{\partial}{\partial \beta_0} \beta_0 + \beta_1 x_i = 1.$$

$$\frac{\partial \mu_i}{\partial \beta_1} = \frac{\partial}{\partial \beta_1} \beta_0 + \beta_1 x_i = x_i$$

# Vetor gradiente

- Vetor gradiente,

$$\begin{aligned}\nabla f(\beta_0, \beta_1) &= \left( -2 \sum_{i=1}^n \epsilon_i(1); -2 \sum_{i=1}^n \epsilon_i x_i \right) \\ &= \left( -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i); -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i \right).\end{aligned}$$

- Resolver o sistema de equações:

$$-2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad (1)$$

$$-2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i = 0 \quad (2)$$

# Resolvendo o sistema de equações

- Pela Eq. (1) temos,

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}. \quad (3)$$

- Substituindo Eq.(3) em Eq. (2) e resolvendo em  $\hat{\beta}_1$ , temos

$$\hat{\beta}_1 = \frac{\bar{y} \sum_{i=1}^n x_i - \sum_{i=1}^n y_i x_i}{\bar{x} \sum_{i=1}^n x_i - \sum_{i=1}^n x_i^2}.$$

# Implementação em R

## ► Simulando um conjunto de dados

```
set.seed(123)
b0 = 10
b1 = 5
x <- seq(0,10, l = 20)
mu <- b0 + b1*x
y <- rnorm(20, mean = mu, sd = 5)
head(cbind(y, x))

##           y           x
## [1,]  7.197622 0.0000000
## [2,] 11.480691 0.5263158
## [3,] 23.056699 1.0526316
## [4,] 18.247279 1.5789474
## [5,] 21.172754 2.1052632
## [6,] 31.733220 2.6315789


b1 <- (mean(y)*sum(x) - sum(y*x))/(mean(x)*sum(x) - sum(x^2))
b0 <- mean(y) - b1*mean(x)
c(b0,b1)

## [1] 11.470239  4.847576


# Conferindo
coef(lm(y ~ x))

## (Intercept)           x
##    11.470239    4.847576
```

# Visualizando a reta ajustada



# Visualizando a superfície objetivo



# Discussão

- ▶ Derivadas são essenciais em *data science*.
- ▶ Maximizar/Minimizar funções perda/objetivo.
- ▶ O cálculo é por vezes difícil e tedioso.
- ▶ Solução de sistemas lineares é tedioso quando possível.
- ▶ Álgebra linear ajuda a generalizar as soluções.
- ▶ Em situações mais gerais expressões analíticas não serão possíveis de obter.
- ▶ Métodos numéricos para resolução de sistema não-lineares.
- ▶ Métodos numéricos de otimização.



# Integrais



# Integral de uma função

- ▶ Integral indefinida: É o oposto ou inverso da derivada, também chamada de **antiderivada**.
- ▶ Sendo  $g(x)$  a derivada de  $f(x)$ , então a antiderivada ou integral indefinida de  $g(x)$  é  $f(x)$ , sendo escrita como:

$$f(x) = \int g(x)dx.$$

- ▶ Exemplo:  $\int xdx = \frac{x^2}{2}$ . Uma vez que,

$$\frac{\partial}{\partial x} \frac{x^2}{2} = \frac{2x^{2-1}}{2} = x.$$


# Integral de uma função

- ▶ Integral definida  $I$  é denotado por

$$I = \int_a^b f(x)dx.$$

- ▶ A integral é um número, e existe em um intervalo fechado  $[a, b]$ .
- ▶ Considere uma função  $f(x)$  definida e contínua no intervalo  $[a, b]$ .
- ▶ O domínio de  $f(x)$  pode ser dividido em  $n$  subintervalos definidos por  $\Delta x_i = x_{i+1} - x_i$ , onde  $i = 1, \dots, n$ .
- ▶ Soma de Riemann


$$\sum_{i=1}^n f(c_i) \Delta x_i$$

onde  $c_i$  é um número pertencente ao subintervalo  $[x_i, x_{i+1}]$ . 

# Integral definida


- A integral definida é obtida como o limite da soma de Riemann quando a largura de todos os subintervalos de  $[a, b]$  tende a zero:

$$I = \int_a^b f(x)dx = \lim_{\Delta x_i \rightarrow 0} \sum_{i=1}^n f(c_i) \Delta x_i.$$



# Integral definida

- ▶ Aumentando o número de retângulos a área é melhor aproximada.
- ▶ Quando  $n \rightarrow \infty$  ou  $\Delta x_i \rightarrow 0$  a soma de Riemann corresponde a área abaixo da curva  $f(x)$ .



- ▶ Podemos facilmente imitar essa ideia numericamente em R.


# Soma de Riemann

## ► Função para calcular a soma de Riemann.

```
soma_riemann <- function(n, a, b, fx, ...) {  
  intervalos <- seq(a, b, length = n)  
  ci <- c()  
  soma <- c()  
  for(i in 1:c(n-1)) {  
    Deltai <- (intervalos[i+1] - intervalos[i]) # Tamanho do intervalo  
    ci[i] <- (intervalos[i+1] + intervalos[i])/2 # Ponto central do intervalo  
    soma[i] <- fx(ci[i])*Deltai # Cada elemento da soma  
  }  
  return(sum(soma))  
}  
soma_riemann <- Vectorize(soma_riemann, "n")
```

# Soma de Riemann

- Calculando a área abaixo da curva  $f(x) = x^2$  em  $[1, 2]$ .



- Valor aproximado com  $n = 100$ .

```
soma_riemann(n = 100, a = 1, b = 2, fx = fx)
```

```
## [1] 2.333325
```

# Teorema fundamental do cálculo

- ▶ Se uma função  $f(x)$  é contínua ao longo do intervalo  $[a, b]$  e  $F(x)$  é a antiderivada de  $f(x)$  ao longo desse mesmo intervalo, então

$$\int_a^b f(x)dx = F(b) - F(a).$$

- ▶ Existem tabelas de antiderivadas.
- ▶ Por exemplo, sendo  $n$  um natural ( $n \neq -1$ ) temos

$$\int x^n dx = \frac{x^{(n+1)}}{n+1}.$$

- ▶ Assim, temos

$$\int_1^2 x^2 dx = F(2) - F(1) = \frac{x^3}{3} \Big|_{x=2} - \frac{x^3}{3} \Big|_{x=1} = \frac{8}{3} - \frac{1}{3} = \frac{7}{3} = 2.33 \dots$$

# Propriedades e Regras básicas de Integração

- ▶ Sejam  $f(x)$  e  $g(x)$  funções contínuas em um certo intervalo e  $k$  uma constante. São válidas as propriedades:

1.  $\int k f(x) dx = k \int f(x) dx.$
2.  $\int [f(x) + g(x)] dx = \int f(x) dx + \int g(x) dx.$
3.  $\int f'(x) g(x) dx = f(x) g(x) - \int f(x) g'(x) dx.$

- ▶ Regras básicas de integração:

1.  $\int k dx = kx + c.$
2.  $\int x^n dx = \frac{x^{n+1}}{n+1}.$
3.  $\int \frac{1}{x} dx = \ln |x| + c.$
4.  $\int \exp x dx = \exp x + c.$
5.  $\int a^x dx = \frac{a^x}{\ln(a)} + c.$

- ▶ Ver tabela no material suplementar.
- ▶ Lista de exercícios.



# Discussão

- ▶ Integrais são extremamente úteis para obter alguns resultados teóricos em probabilidade.
- ▶ Técnicas (básicas) de modelagem estatística e *machine learning* não usam integrais diretamente.
- ▶ Em geral integrais são mais difíceis de calcular do que derivadas.
- ▶ É possível estender a ideia de integrais para funções com duas ou mais variáveis de forma análoga feita para derivadas.
- ▶ Integrais em alta dimensão são extremamente difíceis de calcular e/ou aproximar numericamente.