

# Inferência Estatística

com ênfase na verossimilhança

Paulo Justiniano Ribeiro Jr.  
Wagner Hugo Bonat  
Elias Teixeira Krainski  
Walmes Marques Zeviani

**LEG:** Laboratório de Estatística e Geoinformação  
Universidade Federal do Paraná

Especialização DSBD, 8, 15 e 22/06/2018

# Comentários

- Texto de referência:
  - Página: <http://www.leg.ufpr.br/mcie>
  - Capítulos 1 e 2
- Motivações e propósitos do texto e das aulas
  - Visão unificada e intuitiva dos princípios de inferência estatística
  - Experiências/exposição das gerações
  - Facilidade de recursos computacionais e linguagens
  - Uso de rotinas *versus* implementação/teste/ilustração/aprendizado
  - Uso crítico e avaliação e apreciação das limitações de rotinas

# Exemplo introdutório

Visitando um exemplo simples:

- População:  $X \sim B(\theta)$

# Exemplo introdutório

Visitando um exemplo simples:

- População:  $X \sim B(\theta)$
- Amostra:  $x_1, \dots, x_n$

# Exemplo introdutório

Visitando um exemplo simples:

- População:  $X \sim B(\theta)$
- Amostra:  $x_1, \dots, x_n$
- O que podemos falar sobre  $\theta$ ?
  - Qual a informação contida na amostra?
  - Consideram-se outras fontes de informação?

# Exemplo introdutório

Visitando um exemplo simples:

- População:  $X \sim B(\theta)$
- Amostra:  $x_1, \dots, x_n$
- O que podemos falar sobre  $\theta$ ?
  - Qual a informação contida na amostra?
  - Consideram-se outras fontes de informação?
- informação na amostra resumida por  $\left(n, y = \frac{\sum_{i=1}^n x_i}{n}\right)$  ?

# Espaço do Modelo




- O espaço definido pelo modelo (3-D)

$$\binom{n}{y} \theta^y (1 - \theta)^{n-y}$$

# Espaço do Modelo

- O espaço definido pelo modelo (3-D)


$$\binom{n}{y} \theta^y (1 - \theta)^{n-y}$$





# Objetivos de Inferência

Objetivos de inferência e a função de verossimilhança



## Elementos

- função de verossimilhança  
probabilidade da amostra obtida para diferentes valores de  $\theta$

## Elementos

- função de verossimilhança  
probabilidade da amostra obtida para diferentes valores de  $\theta$
- **melhor** estimador

# Elementos

- função de verossimilhança  
probabilidade da amostra obtida para diferentes valores de  $\theta$
- **melhor** estimador
- conjunto de valores **razoavelmente compatíveis** com a amostra

# Elementos

- função de verossimilhança  
probabilidade da amostra obtida para diferentes valores de  $\theta$
- **melhor** estimador
- conjunto de valores **razoavelmente compatíveis** com a amostra
- **decidir** entre dois valores o mais compatível com a amostra

# Elementos

- função de verossimilhança  
probabilidade da amostra obtida para diferentes valores de  $\theta$
- **melhor** estimador
- conjunto de valores **razoavelmente compatíveis** com a amostra
- **decidir** entre dois valores o mais compatível com a amostra
- **decidir** se a amostra é compatível com certo valor  $\theta_0$  de interesse?

# Elementos

- função de verossimilhança  
probabilidade da amostra obtida para diferentes valores de  $\theta$
- **melhor** estimador
- conjunto de valores **razoavelmente compatíveis** com a amostra
- **decidir** entre dois valores o mais compatível com a amostra
- **decidir** se a amostra é compatível com certo valor  $\theta_0$  de interesse?
- **suposições/pressupostos**

# Elementos

- função de verossimilhança  
probabilidade da amostra obtida para diferentes valores de  $\theta$
- **melhor** estimador
- conjunto de valores **razoavelmente compatíveis** com a amostra
- **decidir** entre dois valores o mais compatível com a amostra
- **decidir** se a amostra é compatível com certo valor  $\theta_0$  de interesse?
- **suposições/pressupostos**
- **relações e contrastes** com outros métodos



# Paradigmas para inferência

## Diferentes Paradigmas no tratamento da incerteza

- Verossimilhança
- Frequentista (espaço amostral / Newman-Pearson)
- Bayesiano

## Inferência Frequentista

- Baseia-se em considerar o comportamento das quantidades de interesse medidas na amostra, supondo que diversas amostras fossem tomadas da população.

# Inferência Frequentista

- Baseia-se em considerar o comportamento das quantidades de interesse medidas na amostra, supondo que diversas amostras fossem tomadas da população.
- Tais quantidades, por serem baseadas em amostras aleatórias são portanto aleatórias, e possuem alguma distribuição de probabilidades.

# Inferência Frequentista

- Baseia-se em considerar o comportamento das quantidades de interesse medidas na amostra, supondo que diversas amostras fossem tomadas da população.
- Tais quantidades, por serem baseadas em amostras aleatórias são portanto aleatórias, e possuem alguma distribuição de probabilidades.
- Tal distribuição de probabilidades é chamada de distribuição amostral.

# Inferência Frequentista

- Baseia-se em considerar o comportamento das quantidades de interesse medidas na amostra, supondo que diversas amostras fossem tomadas da população.
- Tais quantidades, por serem baseadas em amostras aleatórias são portanto aleatórias, e possuem alguma distribuição de probabilidades.
- Tal distribuição de probabilidades é chamada de distribuição amostral.
- As inferências frequentistas são baseadas em probabilidades medidas nestas distribuições.

# Inferência Frequentista

- Baseia-se em considerar o comportamento das quantidades de interesse medidas na amostra, supondo que diversas amostras fossem tomadas da população.
- Tais quantidades, por serem baseadas em amostras aleatórias são portanto aleatórias, e possuem alguma distribuição de probabilidades.
- Tal distribuição de probabilidades é chamada de distribuição amostral.
- As inferências frequentistas são baseadas em probabilidades medidas nestas distribuições.
- Usual nos métodos, técnicas e procedimentos de estatística, especialmente os ligados a cursos e textos básicos e aplicados a diversas áreas.

# Inferência Frequentista

- Baseia-se em considerar o comportamento das quantidades de interesse medidas na amostra, supondo que diversas amostras fossem tomadas da população.
- Tais quantidades, por serem baseadas em amostras aleatórias são portanto aleatórias, e possuem alguma distribuição de probabilidades.
- Tal distribuição de probabilidades é chamada de distribuição amostral.
- As inferências frequentistas são baseadas em probabilidades medidas nestas distribuições.
- Usual nos métodos, técnicas e procedimentos de estatística, especialmente os ligados a cursos e textos básicos e aplicados a diversas áreas.
- As distribuições amostrais podem ser obtidas analiticamente em alguns casos (e.g teste- $t$ ), aproximadas por distribuições conhecidas, ou obtidas por procedimentos computacionais intensivos (e.g. testes aleatorizados e bootstrap).

# Inferência Bayesiana

- Extensão da definição do modelo:

$$[Y|\theta] \sim B(n, \theta)$$

$$[\theta] \sim Pr(a, b) \text{ (priori)}$$

- permite obter (via teorema de Bayes)

$$[\theta|y] \propto [Y|\theta][\theta]$$

$$[\theta|y] \sim \pi(a^*, b^*) \text{ (posteriori)}$$

- Analogias diretas para estimação (pontual e intervalar),
- ... mas não diretas ou triviais para testes de hipótese (valores na *posteriori* sem analogias diretas com razão de verossimilhanças).



# Inferência Bayesiana

No contexto do exemplo de estimação de proporção:

- Priori:  $[\theta] \sim \text{Beta}(a, b)$  (distribuição Beta)
- Verossimilhança:  $[Y|\theta] \sim \text{Bin}(n, \theta)$  (em  $\theta$ , é proporcional à distribuição Beta)
- Posteriori:  $[\theta|y] \sim \text{Beta}(a + y, b + n)$  (distribuição Beta - conjugada)  
(detalhes apresentados durante a aula)

## Paradigmas para inferência

- Paradigmas ...
  - Frequentista (espaço amostral / Newman-Pearson)
  - Verossimilhança
  - Bayesiano

## Paradigmas para inferência

- Paradigmas ...
  - Frequentista (espaço amostral / Newman-Pearson)
  - Verossimilhança
  - Bayesiano
- ... respondem a diferentes perguntas:

# Paradigmas para inferência

- Paradigmas ...
  - Frequentista (espaço amostral / Newman-Pearson)
  - Verossimilhança
  - Bayesiano
- ...respondem a diferentes perguntas:
  - O que devo fazer?

# Paradigmas para inferência

- Paradigmas ...
  - Frequentista (espaço amostral / Newman-Pearson)
  - Verossimilhança
  - Bayesiano
- ...respondem a diferentes perguntas:
  - O que devo fazer?
  - O que os dados dizem?

## Paradigmas para inferência

- Paradigmas ...
  - Frequentista (espaço amostral / Newman-Pearson)
  - Verossimilhança
  - Bayesiano
- ... respondem a diferentes perguntas:
  - O que devo fazer?
  - O que os dados dizem?
  - Em que devo acreditar?

# Paradigmas para inferência

- Paradigmas ...
  - Frequentista (espaço amostral / Newman-Pearson)
  - Verossimilhança
  - Bayesiano
- ... respondem a diferentes perguntas:
  - O que devo fazer?
  - O que os dados dizem?
  - Em que devo acreditar?
- Uma provocação à reflexão (**Royall, 1997:**)

*"Fortunately we are not forced to choose either of these two evils, the sample-space dependence of the frequentists or the prior distribution of the Bayesians.*

**Likelihood methods avoid both sources of subjectivity.**

# Função de Verossimilhança

## Definição informal:

*Dada pela expressão da distribuição conjunta de todas as v.a.'s observáveis ( $Y$ ) o modelo. ou Distribuição conjunta de todas as v.a.'s especificadas no modelo, integrada sobre as não observáveis.*

Notação:  $[\cdot]$  (função de) distribuição de  $\cdot$

Casos de particular interesse:

- Distribuições e modelos de regressão

$$[Y|\theta]$$



# Função de Verossimilhança

## Definição informal:

*Dada pela expressão da distribuição conjunta de todas as v.a.'s observáveis ( $Y$ ) o modelo. ou Distribuição conjunta de todas as v.a.'s especificadas no modelo, integrada sobre as não observáveis.*

Notação:  $[\cdot]$  (função de) distribuição de  $\cdot$

Casos de particular interesse:

- Distribuições e modelos de regressão

$$[Y|\theta]$$

- Modelos hierárquicos (mistos, efeitos aleatórios, longitudinais, espaciais, etc)

$$[Y|\theta] = \int [Y, b|\theta] d b = \int [Y|b, \theta][b|\theta] d b$$

# Função de Verossimilhança

## Definição informal:

*Dada pela expressão da distribuição conjunta de todas as v.a.'s observáveis ( $Y$ ) o modelo. ou Distribuição conjunta de todas as v.a.'s especificadas no modelo, integrada sobre as não observáveis.*

Notação:  $[\cdot]$  (função de) distribuição de  $\cdot$

Casos de particular interesse:

- Distribuições e modelos de regressão

$$[Y|\theta]$$

- Modelos hierárquicos (mistos, efeitos aleatórios, longitudinais, espaciais, etc)

$$[Y|\theta] = \int [Y, b|\theta] d b = \int [Y|b, \theta][b|\theta] d b$$

- inclui Inf. Bayesiana com especificação de  $[\theta]$

# Expressão da Verossimilhança I

**V.A. observável discreta (não há ambiguidade)**

$$L(\theta) \equiv P_{\theta}[Y = y]$$

**Exemplo:**  $Y \sim P(\lambda)$

$$L(\lambda) = \prod_{i=1}^n \frac{\exp\{-\lambda\} \lambda^{Y_i}}{Y_i!} = \frac{\exp\{-n\lambda\} \lambda^{\sum_{i=1}^n Y_i}}{\prod_{i=1}^n Y_i!}$$

$$\propto \exp\{-n\lambda\} \lambda^{\sum_{i=1}^n Y_i}$$

# Expressão da Verossimilhança II

**V.A. contínua: medição à certa precisão** ( $y_{il} \leq y_i \leq y_{is}$ )

- Forma mais geral

$$L(\theta) = P_{\theta}[y_{1l} \leq y_1 \leq y_{1s}, \dots, y_{nl} \leq y_n \leq y_{ns}]$$

# Expressão da Verossimilhança II

**V.A. contínua: medição à certa precisão** ( $y_{il} \leq y_i \leq y_{is}$ )

- Forma mais geral

$$L(\theta) = P_{\theta}[y_{1l} \leq y_1 \leq y_{1s}, \dots, y_{nl} \leq y_n \leq y_{ns}]$$

- Sob independência

$$\begin{aligned} L(\theta) &= P_{\theta}[y_{1l} \leq y_1 \leq y_{1s}] \cdot P_{\theta}[y_{2l} \leq y_2 \leq y_{2s}] \dots P_{\theta}[y_{nl} \leq y_n \leq y_{ns}] \\ &= \prod_{i=1}^n P_{\theta}[y_{il} \leq y_i \leq y_{is}] \end{aligned}$$

## Expressão da Verossimilhança II

**V.A. contínua: medição à certa precisão** ( $y_{il} \leq y_i \leq y_{is}$ )

- Forma mais geral

$$L(\theta) = P_{\theta}[y_{1l} \leq y_1 \leq y_{1s}, \dots, y_{nl} \leq y_n \leq y_{ns}]$$

- Sob independência

$$\begin{aligned} L(\theta) &= P_{\theta}[y_{1l} \leq y_1 \leq y_{1s}] \cdot P_{\theta}[y_{2l} \leq y_2 \leq y_{2s}] \dots P_{\theta}[y_{nl} \leq y_n \leq y_{ns}] \\ &= \prod_{i=1}^n P_{\theta}[y_{il} \leq y_i \leq y_{is}] \end{aligned}$$

- Se grau de precisão comum, ( $y_i - \delta/2 \leq Y_i \leq y_i + \delta/2$ );

$$L(\theta) = \prod_{i=1}^n P_{\theta}[y_i - \delta/2 \leq Y_i \leq y_i + \delta/2] = \prod_{i=1}^n \int_{y_i - \delta/2}^{y_i + \delta/2} f(y_i, \theta) d(y_i).$$

## Expressão da Verossimilhança II (cont)

- alto grau de precisão ( $\delta$  é pequeno em relação a variabilidade dos dados)

$$L(\theta) \approx \left( \prod_{i=1}^n f(y_i, \underline{\theta}) \right) \delta^n,$$

## Expressão da Verossimilhança II (cont)

- alto grau de precisão ( $\delta$  é pequeno em relação a variabilidade dos dados)

$$L(\theta) \approx \left( \prod_{i=1}^n f(y_i, \underline{\theta}) \right) \delta^n,$$

- e se  $\delta$  não depende dos valores dos parâmetros

$$L(\theta) \approx \prod_{i=1}^n f(y_i, \underline{\theta})$$



## Expressão da Verossimilhança II (cont)

- alto grau de precisão ( $\delta$  é pequeno em relação a variabilidade dos dados)

$$L(\theta) \approx \left( \prod_{i=1}^n f(y_i, \underline{\theta}) \right) \delta^n,$$

- e se  $\delta$  não depende dos valores dos parâmetros

$$L(\theta) \approx \prod_{i=1}^n f(y_i, \underline{\theta})$$

- observações não independentes - densidade multivariada:

$$L(\theta) \approx f(\underline{y}, \underline{\theta})$$

# Verossimilhança e Informação

Considere  $Y \sim N(\theta, 1)$  e as seguintes observações.

- 1  $x = 2.45$
- 2  $0.9 < x < 4$
- 3 somente o máximo de uma amostra de tamanho cinco é fornecido  
 $x_{(5)} = 3.5$

# Verossimilhança e Informação

Considere  $Y \sim N(\theta, 1)$  e as seguintes observações.

- ①  $x = 2.45$
- ②  $0.9 < x < 4$
- ③ somente o máximo de uma amostra de tamanho cinco é fornecido  
 $x_{(5)} = 3.5$

Verossimilhança:

$$L(\theta; x) = \phi(x - \theta) \equiv \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}(x - \theta)^2\right\};$$

$$L_1 = L(\theta; x = 2.45) = \phi(x - \theta) = \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}(2.45 - \theta)^2\right\};$$

$$L_2 = L(\theta; 0.9 < x < 4) = \Phi(4 - \theta) - \Phi(0.9 - \theta);$$

$$L_3 = L(\theta; x_{(5)} = 3.5) = n\{\Phi(x_{(n)} - \theta)\}^{n-1}\phi(x_{(n)} - \theta).$$

Para última - argumento multinomial e com




$$F(y) = P(X_{\{n\}} \leq y) = P[X_{\{i\}} < y \forall i \neq n \text{ e } X_{\{n\}} = y]$$

# Verossimilhança e Informação (cont)

```

L1 <- function(theta) dnorm(2.45, m=theta, sd=1)
L2 <- function(theta)
  pnorm(4,mean=theta,sd=1)-pnorm(0.9,mean=theta,sd=1)
L3 <- function(theta)
  5*pnorm(3.5,m=theta,s=1)^4 * dnorm(3.5,m=theta,s=1)

```



# Formas alternativas

- Verossimilhança:

$$L(\theta)$$

- Verossimilhança Relativa:

$$LR(\theta) = \frac{L(\theta)}{L(\hat{\theta})}$$

- log-Verossimilhança:

$$l(\theta) = \log\{L(\theta)\}$$

- Deviance*:

$$D(\theta) = -2 \log\{LR[\theta]\} = -2\{l[\theta] - l[\hat{\theta}]\}$$

$$\text{EMV: } \hat{\theta} = \sup_{\Theta} L[\theta]$$

Quando possível obtido por:  $\hat{\theta} = \max_{\Theta} l[\theta]$

# Exemplo: distribuição Poisson

$$L[\theta] = \frac{\exp\{-n\lambda\} \lambda^{\sum_{i=1}^n Y_i}}{\prod_{i=1}^n Y_i!}$$

$$LR[\theta] = \exp\{-n(\lambda - \hat{\lambda})\} (\lambda/\hat{\lambda})^{n\bar{Y}}$$

$$l[\theta] = -n\lambda + n\bar{Y} \log(\lambda) - \sum_{i=1}^n \log(Y_i!)$$

$$D(\theta) = 2n\{(\lambda - \hat{\lambda}) - \bar{Y} \log(\lambda/\hat{\lambda})\}$$

$$\hat{\theta} = \bar{Y}$$

# Exemplo: Distribuição Poisson

## 1 Código 1

```
veroPois <- function(par, dados, tipo, maxlogL){
  tipo = match.arg(tipo, choices=c("L","LR","logL","dev"))
  ll <- sapply(par, function(p) sum(dpois(dados, lambda=p,
                                          log=TRUE)))


  return(switch(tipo, "L" = exp(ll),
                  "LR" = exp(ll-maxlogL),
                  "logL" = ll,
                  "dev" = 2*(maxlogL-ll)))}
```

## 2 Código 2

```
veroPois <- function(par, amostra, tipo="logL", maxlogL){
  tipo = match.arg(tipo, choices=c("L","LR","logL","dev"))
  ll <- with(amostra, -n*par + soma * log(par))
  return(switch(tipo, "L" = exp(ll),
                  "LR" = exp(ll-maxlogL),
                  "logL" = ll,
                  "dev" = 2*(maxlogL-ll)))}
```

# Exemplo: Distribuição Poisson (cont)

```
mll <- veroPois(emv, amostra=am, tipo="logL")
...
curve(veroPois(x, amostra=am, tipo="dev", maxlogL=mll), 8, 11,
      ylab=expression(D(lambda)), xlab=expression(lambda))
```





# Funções de Interesse

- Função escore:  $U(\theta) = l'(\theta)$
- Hessiano/Informação observada:  $I_O(\theta) = -H(\theta) = -l''(\theta)$
- Informação Esperada:  $I_E(\theta) = E_Y[I_O(\theta)]$
- Estimadas:  $I_O(\hat{\theta})$  e  $I_E(\hat{\theta})$

# Funções de Interesse

- Função escore:  $U(\theta) = I'(\theta)$
- Hessiano/Informação observada:  $I_O(\theta) = -H(\theta) = -I''(\theta)$
- Informação Esperada:  $I_E(\theta) = E_Y[I_O(\theta)]$
- Estimadas:  $I_O(\hat{\theta})$  e  $I_E(\hat{\theta})$

## Propriedades assintóticas:

- $\underline{\hat{\theta}} \sim NM_d(\underline{\theta}, I_E(\underline{\theta})^{-1})$
- Assintoticamente equivalentes:

$$\underline{\hat{\theta}} \sim NM_d(\underline{\theta}, I_E(\underline{\hat{\theta}})^{-1})$$

$$\underline{\hat{\theta}} \sim NM_d(\underline{\theta}, I_O(\underline{\theta})^{-1})$$

$$\underline{\hat{\theta}} \sim NM_d(\underline{\theta}, I_O(\underline{\hat{\theta}})^{-1}).$$

- $D(\underline{\theta}) = -2[l(\underline{\theta}) - l(\underline{\hat{\theta}})] \sim \chi_d^2$

## Exemplo: Distribuição Poisson (cont)

$$L(\lambda) = \prod_{i=1}^n \frac{\exp\{-\lambda\} \lambda^{Y_i}}{Y_i!} = \frac{\exp\{-n\lambda\} \lambda^{\sum_{i=1}^n Y_i}}{\prod_{i=1}^n Y_i!}$$

$$l(\lambda) = -n\lambda + \left(\sum_{i=1}^n Y_i\right) \log(\lambda) - \sum_{i=1}^n \log Y_i!$$

$$U(\lambda) = -n + \frac{\sum_{i=1}^n Y_i}{\lambda}$$

$$U(\hat{\lambda}) = 0 \longrightarrow \hat{\lambda} = \frac{\sum_{i=1}^n Y_i}{n} = \bar{Y}$$

$$l_O(\lambda) = \frac{\sum_{i=1}^n Y_i}{\lambda^2} ; l_E(\lambda) = \frac{n}{\lambda} ; l_O(\hat{\lambda}) = l_E(\hat{\lambda}) = \frac{n^2}{\sum_{i=1}^n Y_i}$$

$$V(\hat{\lambda}) = l_E(\lambda)^{-1} \approx l_O(\lambda)^{-1} \approx l_O(\hat{\lambda})^{-1} = l_E(\hat{\lambda})^{-1}$$

## Exemplo: Distribuição Poisson (cont)

Função escore:

```
UPois <- function(lambda, amostra){  
  return(with(amostra, n - soma/lambda))  
}
```


Hessiano (informação estimada):

```
HPois <- function(lambda, amostra){  
  return(with(amostra, soma/lambda^2))  
}
```



# Estimação

Objetivos de inferência e a função de verossimilhança



# Obtendo o EMV

- analiticamente:  
estudando comportamento de  $l(\theta)$  ou resolvendo  $U(\theta) = 0$
- numericamente (otimização/aproximações numéricas)
  - Solução da(s) equação(ões) de estimação (função escore)
    - com uso de derivadas (ex: Newton-Raphson)
    - sem uso de derivadas (ex: Brent)
  - Maximização da função de (log)-verossimilhança
- Outros (ex: EM)
- Simulação (ex: verossimilhança Monte Carlo, *data-cloning*, ...)
- Aproximações da verossimilhança (pseudo-verossimilhanças)

# Estimadores e Inferência

- Análogos para distribuições *posteriori* em Inferência Bayesiana
- maximização numérica: mais comum em EMV
- simulação: mais usual em Inferência Bayesiana

## EMV

Newton Raphson: expansão (Taylor) de 1ª ordem de  $U(\theta)$ :

$$\lambda^{r+1} = \lambda^r - \frac{U(\lambda)}{H(\lambda)}$$

```
maxit <- 100; lambdaNR <- 5; iter <- 0; d <- 1
while(d > 1e-12 & iter <= maxit){
  lambdaNR.new <-
    lambdaNR - UPois(lambdaNR, am)/HPois(lambdaNR, am)
  d <- abs(lambdaNR - lambdaNR.new)
  lambdaNR <- lambdaNR.new ; iter <- iter + 1
}
c(lambdaNR, iter)
```

Variante - *Fisher scoring*:  $-H(\lambda) \rightarrow I_E(\lambda)$



# Exemplo: Distribuição Poisson (cont)

- Solução de equação  $U(\theta) = 0$ :

```
uniroot(UPois, interval=range(y), amostra=am)$root
```


- Maximização da verossimilhança

```
optimize(veroPois, interval=range(y), maximum=TRUE, amostra=am)
optim(par = median(y), fn=veroPois, control=list(fnscale=-1),
      amostra=am)
```

- uso do gradiente: argumento `gr = Upois`
- pode retornar hessiano numérico ( $I_O(\hat{\theta})$  obtido numericamente)

# Intervalo de Confiança

Objetivos de inferência e a função de verossimilhança



# Intervalo de confiança

- Região definida por corte na função de verossimilhança
  - $LR(\theta) \geq r$
  - $l(\theta) \geq c$
  - $D(\theta) \leq c^*$

# Intervalo de confiança

- Região definida por corte na função de verossimilhança
  - $LR(\theta) \geq r$
  - $I(\theta) \geq c$
  - $D(\theta) \leq c^*$
- Definição do ponto de corte
  - a) comportamento assintótico  $D(\theta) \sim \chi_p^2$
  - b) interpretação probabilística direta em inf. Bayesiana (quantis ou HPD)
  - c) interpretação de evidência relativa em  $LR(\theta)$

# Intervalo de confiança

- Região definida por corte na função de verossimilhança
  - $LR(\theta) \geq r$
  - $I(\theta) \geq c$
  - $D(\theta) \leq c^*$
- Definição do ponto de corte
  - comportamento assintótico  $D(\theta) \sim \chi_p^2$
  - interpretação probabilística direta em inf. Bayesiana (quantis ou HPD)
  - interpretação de evidência relativa em  $LR(\theta)$
- Relações entre (a) e (c)

$r$	$c$	$c^*$	$P[ Z  < \sqrt{c^*}]$
50%	0,693	1,386	0,761
26%	1.661	3,321	0,899
15%	1,897	3,794	0,942
3,6%	3,324	6,648	0,990

- c.1) evidência por analogia sobre diferenças em  $LR(\theta)$ ,  $I(\theta)$  ou  $D(\theta)$

## analogia...



# Limites do Intervalo

## ① Solução de equação (analítica ou numérica)

- $LR(\theta) = r$
- $I(\theta) = c$
- $D(\theta) = c^*$

# Limites do Intervalo

## 1 Solução de equação (analítica ou numérica)

- $LR(\theta) = r$
- $I(\theta) = c$
- $D(\theta) = c^*$

## 2 Aproximação quadrática (Taylor)

$$D(\theta) = -2[I(\theta) - I(\hat{\theta})] =$$

$$= -2 \left\{ [I(\hat{\theta}) + (\theta - \hat{\theta})I'(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^2 I''(\hat{\theta})] - I(\hat{\theta}) \right\}$$

$$D(\theta) = -(\theta - \hat{\theta})^2 I''(\hat{\theta}) \leq c^*$$

$$\tilde{\theta} = \hat{\theta} \pm \sqrt{\frac{c^*}{-I''(\hat{\theta})}}$$



# Limites do Intervalo

## 1 Solução de equação (analítica ou numérica)

- $LR(\theta) = r$
- $l(\theta) = c$
- $D(\theta) = c^*$

## 2 Aproximação quadrática (Taylor)

$$D(\theta) = -2[l(\theta) - l(\hat{\theta})] =$$

$$= -2 \left\{ [l(\hat{\theta}) + (\theta - \hat{\theta})l'(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^2 l''(\hat{\theta})] - l(\hat{\theta}) \right\}$$

$$D(\theta) = -(\theta - \hat{\theta})^2 l''(\hat{\theta}) \leq c^*$$

$$\tilde{\theta} = \hat{\theta} \pm \sqrt{\frac{c^*}{-l''(\hat{\theta})}}$$

## 3 equivalência com à Distribuição assintótica: $\hat{\theta} \sim NM_d(\underline{\theta}, I_E(\underline{\theta}))$



## Exemplo: Exponencial (i.i.d.)

$$f(y_i, \theta) = \theta \exp\{-\theta y_i\} \quad y > 0 ; \theta > 0$$

$$F(y_i, \theta) = 1 - \exp\{-\theta y_i\} \quad y > 0 ; \theta > 0$$

$$L(\theta) = \theta^n \exp\{-\theta n\bar{y}\}$$

$$l(\theta) = n \log(\theta) - \theta n\bar{y}$$

$$U(\theta) = \frac{n}{\theta} - n\bar{y}$$

$$H(\theta) = -\frac{n}{\theta^2} \quad (\text{depende do valor de } \theta!!)$$

$$\hat{\theta} = 1/\bar{y}$$

# Exemplo: Exponencial (cont)

## Intervalos de confiança

- 1 Corte na deviance: (solução apenas numericamente)

$$D(\theta) = 2n[\log(\hat{\theta}/\theta) + \bar{y}(\theta - \hat{\theta})] \leq c^*$$

# Exemplo: Exponencial (cont)

## Intervalos de confiança

- 1 Corte na deviance: (solução apenas numericamente)

$$D(\theta) = 2n[\log(\hat{\theta}/\theta) + \bar{y}(\theta - \hat{\theta})] \leq c^*$$

- 2 Aproximação quadrática:

$$D(\theta) \approx n \left( \frac{\theta - \hat{\theta}}{\hat{\theta}} \right)^2$$

$$(\hat{\theta}_L \approx \hat{\theta}(1 - \sqrt{c^*/n}) , \quad \hat{\theta}_U \approx \hat{\theta}(1 + \sqrt{c^*/n}))$$

# Exemplo: Exponencial (cont)

## Intervalos de confiança

- ❶ Corte na deviance: (solução apenas numericamente)

$$D(\theta) = 2n[\log(\hat{\theta}/\theta) + \bar{y}(\theta - \hat{\theta})] \leq c^*$$

- ❷ Aproximação quadrática:

$$D(\theta) \approx n \left( \frac{\theta - \hat{\theta}}{\hat{\theta}} \right)^2$$

$$(\hat{\theta}_L \approx \hat{\theta}(1 - \sqrt{c^*/n}), \quad \hat{\theta}_U \approx \hat{\theta}(1 + \sqrt{c^*/n}))$$

- ❸ Distribuição assintótica:  $I_E^{-1}(\theta) \approx I_O^{-1}(\hat{\theta}) = \hat{\theta}^2/n$



$$\hat{\theta} \pm z_{\frac{\alpha}{2}} \sqrt{V(\hat{\theta})}$$

$$\hat{\theta}_L = \hat{\theta} - z_{\alpha} \hat{\theta} / \sqrt{n} \quad \text{e} \quad \hat{\theta}_U = \hat{\theta} + z_{\alpha} \hat{\theta} / \sqrt{n}$$

# Exemplo: Distribuição Exponencial (cont)

```
ICdevExp <- function(theta, theta.hat, y, nivel=0.95){
  n <- length(y)
  dv <- 2*n*( log( theta.hat/theta) + mean(y)*(theta- theta.hat))
  return(dv - qchisq(nivel,df=1))
}
```

```
require(rootSolve)
uniroot.all(ICdevExp, interval=c(0,10), theta.hat=1/mean(y),y=y)
```



# Reparametrização

$$\phi = g(\theta)$$

- $\hat{\phi} = g(\hat{\theta})$
- IC por corte:  $(\hat{\phi}_I, \hat{\phi}_S) = (g(\hat{\theta}_I), g(\hat{\theta}_S))$
- Assintoticamente:  $\hat{\phi} = g(\hat{\theta}) \sim N(\phi, [g'(\theta)]^2 [I_E(\theta)]^{-1})$
- **Método *delta*:**

$$\text{Var}(\hat{\phi}) = [g'(\theta)]^2 [I_E(\theta)]^{-1} \longrightarrow [\text{se}(\hat{\phi}) = |g'(\theta)| [I_E(\theta)]^{-1/2}]$$

- Se transformação  $g(\cdot)$  é não linear, invariância **não é válida** para aproximação quadrática

$$\{g(\hat{\theta}_I), g(\hat{\theta}_S)\} = \{g(\hat{\theta} - z_{\alpha/2} [I_E(\hat{\theta})]^{-1/2}), g(\hat{\theta} + z_{\alpha/2} [I_E(\hat{\theta})]^{-1/2})\} \neq$$

$$(\tilde{\phi}_I, \tilde{\phi}_S) = \{g(\hat{\theta}) - z_{\alpha/2} |g'(\theta)| [I_E(\hat{\theta})]^{-1/2}, g(\hat{\theta}) + z_{\alpha/2} |g'(\theta)| [I_E(\hat{\theta})]^{-1/2}\}$$

- $I(\phi)$  é menos assimétrica:  $(\tilde{\phi}_I, \tilde{\phi}_S)$   
 $I(\theta)$  é menos assimétrica:  $(g(\tilde{\phi}_I), g(\tilde{\phi}_S))$

# Recomendações

- **Melhor abordagem:** (mais geral e acurácia)  
IC's baseados verossimilhança/deviance (muitas vezes só obtidos numericamente)
- **Intervalos assintóticos** (utilizam  $se(\hat{\theta})$ , obtenção a partir da aproximação quadrática, formas fechadas )
- Escolher parametrização da função que forneça uma boa aproximação quadrática
- IC's para funções dos parâmetros: obtenção pelo método delta ou direta se aproximadamente quadrática



# Condições de regularidade

- $\Theta$  é finito dimensional e  $\theta$  é interior a  $\Theta$
- primeiras três derivadas de  $l(\theta)$  na vizinhança de  $\theta$
- amplitude não depende de  $\theta$
- $l(\theta) \approx$  quadrática para  $n \rightarrow \infty$ , passando a depender apenas da posição e curvatura no EMV
- ...  $l_E(\theta)$  precisa ser inversível

# Exemplo: Exponencial (cont)

## Reparametrização

$$\phi = P[Y \leq u] = 1 - \exp\{-\theta u\}$$

- Obter  $se(\hat{\phi})$
- Três intervalos possíveis:

$$(\hat{\phi}_I, \hat{\phi}_S) : (g(\hat{\theta}_I), g(\hat{\theta}_S))$$

$$(\tilde{\phi}_I, \tilde{\phi}_S) : \hat{\phi} \pm z_{\alpha/2} se(\hat{\phi})$$

$$(1 - \exp\{-\tilde{\theta}_S u\}, 1 - \exp\{-\tilde{\theta}_I u\}) : (g(\tilde{\theta}_I), g(\tilde{\theta}_S))$$

- Comparação gráfica das funções e das taxas de cobertura (simulação)



# Exemplo: Distribuição Exponencial (cont)

## Redefinindo


```
ICdevExp <- function(theta, theta.hat, y, nivel=0.95){
  n <- length(y)
  dv <- 2*n*( log( theta.hat/theta) + mean(y)*(theta- theta.hat))
  return(dv - qchisq(nivel,df=1))
}
```

```
require(rootSolve)
uniroot.all(ICdevExp, interval=c(0,10), theta.hat=1/mean(y), y=y)
```

```
ICdevExp <- function(theta, amostra, nivel=0.95){
  ## amostra é um vetor com elementos n e mean(y), nesta ordem
  n <- amostra[1]
  med <- amostra[2]
  dv <- 2*n*(-log(med*theta) + med*theta - 1)
  return(dv - qchisq(nivel, df=1))
}
```

```
am <- c(length(y), mean(y))
uniroot.all(ICdevExp, interval=c(0,10), amostra=am)
```

# Teste de Hipótese



# Teste de Hipótese

- Teste razão de verossimilhança

```
trv <- function(Est, H0, alpha, ...){
  critico <- qchisq(1-alpha, df=1)
  est.calc <- Est(H0, ...)
  print(ifelse(est.calc < critico, "Aceita H0", "Rejeita H0"))
  return(c(est.calc,critico))}
```

- Teste Wald

```
wald <- function(H0, EMV, V.EMV, alpha){
  critico <- qnorm(1-alpha/2)
  Tw <- (EMV - H0)/sqrt(V.EMV)
  print(ifelse(Tw < critico, "Aceita H0", "Rejeita H0"))
  return(c(Tw,critico))
}
```

- Teste Escore

```
escore <- function(H0, U, Ie, alpha, ...){
  critico <- qnorm(1-alpha/2)
  Te <- U(H0,...)/sqrt(Ie(H0,...))
  print(ifelse(Te < critico, "Aceita H0", "Rejeita H0"))
  return(c(Te,critico))
}
```

# Exemplo: Poisson

## TRV

```
Est <- function(H0, x){
  n <- length(x)
  EMV <- mean(x)
  lv <- 2*n*(( H0 - EMV) + EMV*log(EMV/H0))
  return(lv)
}
trv(Est = Est, H0=8, alpha = 0.05, x=x)
```

## Wald

```
wald(H0=8, EMV = mean(x), V.EMV = mean(x)/length(x), alpha=0.05)
```

## Escore

```
fc.escore <- function(lambda,x){
  n <- length(x)
  esco <- -n + sum(x)/lambda
  return(esco)}
Ie <- function(lambda,x){
  n <- length(x)
  I <- n/lambda
  return(I)}
escore(H0 = 8, U = fc.escore, Ie = Ie, alpha=0.05, x=x)
```

# Exemplo: Distribuição Normal

## log-Verossimilhança

$$l(\mu, \sigma) = -\frac{n}{2} \log 2\pi - n \log \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2.$$

## Escore

$$U(\mu) = \frac{\partial l(\mu, \sigma)}{\partial \mu} = \frac{\sum_{i=1}^n y_i}{\sigma^2} - \frac{n\mu}{\sigma^2}$$

$$U(\sigma) = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (y_i - \mu)^2.$$

## EMV

$$\hat{\mu} = \frac{\sum_{i=1}^n y_i}{n} \quad \text{e} \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \mu)^2}{n}.$$

## Informação

$$I_O(\hat{\mu}, \hat{\sigma}) = \begin{bmatrix} \frac{n}{\hat{\sigma}^2} & 0 \\ 0 & \frac{2n}{\hat{\sigma}^2} \end{bmatrix}.$$

# Intervalos de confiança

## Conjuntos

- corte

$$D(\mu, \sigma) = 2[n \log \left( \frac{\sigma}{\hat{\sigma}} \right) + \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 - \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n (y_i - \hat{\mu})]$$

- elipse (aproximação quadrática)


$$D(\mu, \sigma) \approx (\underline{\theta} - \underline{\hat{\theta}})^\top I_o(\underline{\hat{\theta}})(\underline{\theta} - \underline{\hat{\theta}}).$$

- assintótico

$$\begin{bmatrix} \hat{\mu} \\ \hat{\sigma} \end{bmatrix} \sim NM_2 \left( \begin{bmatrix} \mu \\ \sigma \end{bmatrix}, \begin{bmatrix} \hat{\sigma}^2/n & 0 \\ 0 & \hat{\sigma}^2/2n \end{bmatrix} \right)$$



# Exemplo: Distribuição Normal (cont)



# Intervalos de confiança

Parâmetros de interesse e de inconveniência (*nuisance*):  $(\theta, \psi)$

Soluções usuais:

- Condicionando no EMV :  $L(\theta) = L(\theta, \hat{\psi}) \equiv [Y|\theta, \hat{\psi}]$
- Verossimilhança Perfilhada :  $L(\theta) \equiv L[\theta, \hat{\psi}_\theta]$
- Verossimilhanças marginais integradas Bayesianas :  

$$L(\theta) = \int [Y|\theta, \psi][\psi] d\psi$$

# Intervalos de confiança

Parâmetros de interesse e de inconveniência (*nuisance*):  $(\theta, \psi)$

Soluções usuais:

- Condicionando no EMV :  $L(\theta) = L(\theta, \hat{\psi}) \equiv [Y|\theta, \hat{\psi}]$
- Verossimilhança Perfilhada :  $L(\theta) \equiv L[\theta, \hat{\psi}_\theta]$
- Verossimilhanças marginais integradas Bayesianas :  




$$L(\theta) = \int [Y|\theta, \psi][\psi] d\psi$$

Exemplo Normal:  $1/\sigma^2 \sim G(a, b)$

$$f(y|\mu) = \frac{\Gamma(n/2 + 1)}{\pi^{n/2} \Gamma(a) (\sum_i (y_i - \mu)^2 + 2b)^{n/2+a}}$$

Integrações analíticas e por simulação

# Exemplo: Distribuição Normal (cont)



# Exemplo: Distribuição Normal (cont)

```
pl.mu <- function(sigma, mu, dados){
  pll <- sum(dnorm(dados, mean=mu, sd=sigma, log=TRUE))
  return(pll)}

##
pl.sigma <- function(mu, sigma, dados){
  pll <- sum(dnorm(dados, mean=mu, sd=sigma, log=TRUE))
  return(pll)}
```

```
grid.mu <- seq(9, 11.3, length=200)
grid.sigma <- seq(0.65, 2.7, length=200)
## Condicionais:
mu.cond <- sapply(grid.mu, pl.sigma, sigma=sqrt(var(y10)*9/10), dados=y10)
sigma.cond <- sapply(grid.sigma, pl.mu, mu=mean(y10), dados=y10)

mu.perf <- matrix(0, nrow=length(mu), ncol=2)
for(i in 1:length(mu)){
  mu.perf[i,] <- unlist(optimize(pl.mu,c(0,200),
                                mu=mu[i],dados=y10,maximum=TRUE)))}
sigma.perf <- matrix(0, nrow=length(sigma), ncol=2)
for(i in 1:length(sigma)){
  sigma.perf[i,] <- unlist(optimize(pl.sigma,c(0,1000),
                                    sigma=sigma[i],dados=y10,maximum=TRUE)))}
```

# Exemplo: Distribuição Normal (Dados intervalares)

## Dados intervalares:

observações "pontuais":

72,6 81,3 72,4 86,4 79,2 76,7 81,3 ;

observações intervalares:

uma observação com valor acima de 85,

uma observação com valor acima de 80,

quatro observações com valores entre 75 e 80,

seis observações com valores abaixo de 75.

## Contribuições para verossimilhança

$$L(\underline{\theta}) = f(y_i) \text{ para } y_i \text{ pontual,}$$

$$L(\underline{\theta}) = 1 - F(85) \text{ para } y_i > 85,$$

$$L(\underline{\theta}) = 1 - F(80) \text{ para } y_i > 80,$$

$$L(\underline{\theta}) = F(80) - F(75) \text{ para } 75 < y_i < 80,$$

$$L(\underline{\theta}) = F(75) \text{ para } y_i < 75.$$

# Dados intervalares (cont)

```
nllnormI <- function(par, xp, XI) {
  ll1 <- sum(dnorm(xp, mean = par[1], sd = par[2], log = T))
  L2 <- pnorm(XI, mean = par[1], sd = par[2])
  ll2 <- sum(log(L2[, 2] - L2[, 1]))
  return(-(ll1 + ll2))
}
```



	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]	[,12]
[1,]	85	80	75	75	75	75	-Inf	-Inf	-Inf	-Inf	-Inf	-Inf
[2,]	Inf	Inf	80	80	80	80	75	75	75	75	75	75

```
ini <- c(mean(y), sd(y))
ests <- optim(, nllnormI, x=y, XI=yI)$par
```

# Dados intervalares (cont)

## Função deviance genérica.

```
devFun <- function(theta, est, llFUN, ...){
  return(2 * (llFUN(theta, ...) - llFUN(est, ...)))
}
devSurf <- Vectorize(function(x,y, ...) devFun(c(x,y), ...))
```





# Dados intervalares (cont)

## Código mais geral e cuidadoso

```
nllnormI <- function(par, xp, XI, logsigma=FALSE){
  if(logsigma) par[2] <- exp(par[2])
  l11 <- ifelse(missing(xp), 0,
               sum(dnorm(xp, mean=par[1], sd=par[2], log=T)))
  if(missing(XI)) l12 <- 0
  else{
    if(ncol(XI) != 2 || any(XI[,2] <= XI[,1]))
      stop("XI deve ser matrix com 2 colunas com XI[,2] > XI[,1]")
    L2 <- pnorm(XI, mean=par[1], sd=par[2])
    l12 <- sum(log(L2[,2] - L2[,1]))
  }
  return(-(l11 + l12))
}
```



# Outros exemplos (texto)

- ➊ AR1
- ➋ Outro exemplo de reparametrização
- ➌ Gamma
- ➍ Binomial Negativa
- ➎ Processo de Poisson não-homogêneo
- ➏ Modelo espacial Geoestatístico
- ➐ Códigos Genéricos:
  - mle (**stat4**) e mle2 (**bbmle**)
  - profile e confint