

DSBD - Modelos Lineares

Slides: Cesar Taconeli, Apres.: José Padilha

11 de agosto, 2018

Aula 3 - Regressão linear múltipla

Introdução

- A regressão linear múltipla pode ser vista como uma extensão da regressão linear simples, em que **um conjunto de variáveis independentes** são utilizadas para explicar a resposta.
- Ao considerar conjuntamente o efeito de duas ou mais variáveis independentes temos condições de avaliar o efeito de uma particular variável ajustado (controlando) o efeito das demais variáveis.
- A análise de regressão linear com múltiplas variáveis é mais complexa que a regressão linear simples devido à maior dificuldade de encontrar um bom modelo, visualizar e interpretar os resultados.

Definição e propriedades do modelo

- O modelo de regressão linear múltipla é definido da seguinte forma:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \epsilon_i. \quad (1)$$

- Para os erros do modelo de regressão linear múltipla assumimos suposições semelhantes às consideradas para o modelo de regressão linear simples:
 - Linearidade: $E(\epsilon_i) = 0$;
 - Variância constante: $Var(\epsilon_i) = \sigma^2$;
 - Independência: ϵ_i e ϵ_j são independentes para $i \neq j$;
 - x_i é independente de ϵ_i , para todo i ;
 - Normalidade: $\epsilon_i \sim N(0, \sigma^2)$.

Definição e propriedades do modelo

- Como consequências da especificação do modelo, temos:

① $E(y_i | \mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ik})') = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik};$

② $Var(y_i | \mathbf{x}_i) = \sigma^2;$

③ $y_i | \mathbf{x}_i \sim N(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik}, \sigma^2);$

- ④ Condicional aos respectivos vetores de variáveis explicativas, y_i e y_j são independentes, para todo $i \neq j$.

Definição e propriedades do modelo

- Observe que:

$$\frac{\partial E(y|\mathbf{x})}{\partial x_j} = \beta_j \quad (2)$$

Interpretação dos parâmetros do modelo de regressão linear múltipla

β_j representa a alteração esperada na resposta (y) para uma unidade a mais em x_j quando todas as demais variáveis $x_k \neq x_j$ são mantidas fixas.

- Devido a essa interpretação, os parâmetros de regressão (β_j 's) são usualmente chamados **coeficientes de regressão parcial**.

Definição e propriedades do modelo

- O intercepto (β_0) é a resposta esperada no ponto $x_1 = 0, x_2 = 0, \dots, x_k = 0$, caso esse ponto pertença ao escopo do problema;
- A interpretação apresentada para os parâmetros β_j 's somente é válida na ausência de interações;
- Considere o seguinte modelo de regressão linear múltipla com termo de interação:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \epsilon. \quad (3)$$

Definição e propriedades do modelo

- Nesse caso, por exemplo:

$$\frac{\partial E(y|\mathbf{x})}{\partial x_1} = \beta_1 + \beta_3 x_2. \quad (4)$$

- Assim, mantendo x_2 fixa, espera-se uma variação de $\beta_1 + \beta_3 x_2$ em y para cada unidade acrescida em x_1 .
- De forma semelhante, mantendo x_1 fixa, espera-se uma variação de $\beta_2 + \beta_3 x_1$ em y para cada unidade acrescida em x_2 .
- Dessa forma, a superfície de regressão não é mais plana, pois a taxa de variação de x_1 varia conforme o valor de x_2 e vice-versa.

Notação matricial do modelo

- Considere n observações (y_i, \mathbf{x}_i) , em que $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ik})'$:

$$y_1 = \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \dots + \beta_k x_{1k} + \epsilon_1$$

$$y_2 = \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \dots + \beta_k x_{2k} + \epsilon_2$$

$$\vdots$$

$$y_n = \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2} + \dots + \beta_k x_{nk} + \epsilon_n$$

Notação matricial do modelo

- O modelo de regressão linear múltipla fica representado matricialmente por:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad (5)$$

em que

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{bmatrix}, \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix}, \boldsymbol{\epsilon} = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

Notação matricial do modelo

- As especificações e resultados apresentados anteriormente podem ser representados na forma matricial:

① $E(\epsilon) = \mathbf{0};$

② $Var(\epsilon) = \sigma^2 \mathbf{I};$

③ $E(\mathbf{y}|\mathbf{X}) = \mathbf{X}\beta;$

④ $Var(\mathbf{y}|\mathbf{X}) = \sigma^2 \mathbf{I};$

②② $\mathbf{y}|\mathbf{X} \sim Normal(\mathbf{X}\beta, \sigma^2 \mathbf{I}).$

Estimação dos parâmetros do modelo por mínimos quadrados

- Vamos considerar n observações (y_i, \mathbf{x}_i) , em que $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ik})'$.
- A estimação de mínimos quadrados para o modelo de regressão linear múltipla baseia-se, novamente, na determinação de $\beta_0, \beta_1, \dots, \beta_k$ que minimizem a soma de quadrados dos erros:

$$S = S(\beta_0, \beta_1, \dots, \beta_k) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}))^2 \quad (6)$$

Estimação dos parâmetros do modelo por mínimos quadrados

- Os estimadores de mínimos quadrados para $\beta_0, \beta_1, \dots, \beta_k$ devem satisfazer:

$$\frac{\partial S(\beta)}{\partial \beta} = \begin{bmatrix} \frac{\partial S(\beta)}{\partial \beta_0} \\ \frac{\partial S(\beta)}{\partial \beta_1} \\ \frac{\partial S(\beta)}{\partial \beta_2} \\ \vdots \\ \frac{\partial S(\beta)}{\partial \beta_k} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \quad (7)$$

Estimação dos parâmetros do modelo por mínimos quadrados

- Derivando parcialmente em relação aos parâmetros de regressão obtemos:

$$\left. \frac{\partial S}{\partial \beta_0} \right|_{\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k} = -2 \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^k \beta_j x_{ij} \right) = 0 \quad (8)$$

e

$$\left. \frac{\partial S}{\partial \beta_j} \right|_{\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k} = -2 \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^k \beta_j x_{ij} \right) x_{ij} = 0, \quad j = 1, 2, \dots, k. \quad (9)$$

Estimação dos parâmetros do modelo por mínimos quadrados

- Na forma matricial:

$$S(\beta) = \sum_{i=1}^n \epsilon_i^2 = \epsilon' \epsilon = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta), \quad (10)$$

de maneira que o vetor $\hat{\beta}$ tal que:

$$\left. \frac{\partial S}{\partial \beta} \right|_{\hat{\beta}} = \mathbf{0} \quad (11)$$

é o estimador de mínimos quadrados de β , dado por:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}. \quad (12)$$

Estimação dos parâmetros do modelo por mínimos quadrados

- Observe que os estimadores de mínimos quadrados somente existem se a matriz $(\mathbf{X}'\mathbf{X})^{-1}$ existe;
- A condição de existência de $(\mathbf{X}'\mathbf{X})^{-1}$ é que as colunas de \mathbf{X} sejam linearmente independentes, ou seja, que nenhuma coluna de \mathbf{X} seja combinação linear das demais;
- O modelo ajustado, para um vetor $\mathbf{x} = (1, x_1, x_2, \dots, x_k)$ fica denotado por:

$$\hat{y} = \mathbf{x}'\hat{\boldsymbol{\beta}} = \hat{\beta}_0 + \hat{\beta}_1x_1 + \dots + \hat{\beta}_kx_k \quad (13)$$

Estimação dos parâmetros do modelo por mínimos quadrados

- O vetor de valores ajustados $\hat{\mathbf{y}} = (\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n)$ é dado por:

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{H}\mathbf{y}. \quad (14)$$

- A matriz $n \times n$ $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$, chamada matriz chapéu (*hat matrix*) mapeia o vetor de valores observados no vetor de valores ajustados.
- O vetor de resíduos $\mathbf{r} = (r_1, r_2, \dots, r_n)$ fica definido, em notação matricial, por:

$$\mathbf{r} = \mathbf{y} - \hat{\mathbf{y}}, \quad (15)$$

em que $r_i = y_i - \hat{y}_i$, $i = 1, 2, \dots, n$.

Estimação dos parâmetros do modelo por mínimos quadrados

- Propriedades dos estimadores:

① $E(\hat{\beta}) = \beta$ ($\hat{\beta}$ é um estimador não viciado de β);

② $Var(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$;

③ $\hat{\beta}$ é o melhor (mais eficiente) estimador linear não viciado de β (teorema de Gauss Markov);

④ Sob a suposição de que os erros têm distribuição normal os estimadores de mínimos quadrados equivalem aos de máxima verossimilhança.

Estimação de σ^2

- Um estimador não viciado para σ^2 , baseado na soma de quadrados de resíduos, é dado por:

$$\hat{\sigma}^2 = QM_{Res} = \frac{SQ_{Res}}{n - p} = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}, \quad (16)$$

em que $p = k + 1$ é o número de parâmetros do modelo.

Testes de hipóteses e intervalos de confiança para os parâmetros do modelo de RLM

- Assim como no caso de RLS, também na RLM a inferência sobre os parâmetros do modelo é um ponto importante, que permitirá:

- * Checar a significância do modelo ajustado;
 - * Identificar quais variáveis explicativas são relevantes na a
 - * Avaliar o erro de estimativas e previsões geradas pelo model
-
- Deste ponto em diante assumiremos todas as suposições especificadas para os erros, inclusive a de normalidade.

Análise de variância

- Na análise de variância em regressão linear múltipla, a variação total (corrigida pela média) é novamente decomposta em dois componentes: variação explicada pela regressão e variação residual, tal que:

$$SQ_{Total} = SQ_{Reg} + SQ_{Res}. \quad (17)$$

- Usando notação matricial, as somas de quadrados ficam definidas por:

$$SQ_{Res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \mathbf{y}'\mathbf{y} - \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{y}; \quad (18)$$

$$SQ_{Reg} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{y} - \frac{(\sum_{i=1}^n y_i)^2}{n}; \quad (19)$$

$$SQ_{Total} = \sum_{i=1}^n (y_i - \bar{y})^2 = \mathbf{y}'\mathbf{y} - \frac{(\sum_{i=1}^n y_i)^2}{n}. \quad (20)$$

Análise de variância

Tabela 1: Quadro de análise de variância para o modelo de RLM

Fonte de variação	Graus de liberdade	Soma de quadrados	Quadrados médios	F
Regressão	$p - 1$	$\hat{\beta}' \mathbf{X}' \mathbf{y} - \frac{\left(\sum_{i=1}^n y_i\right)^2}{n}$	$QM_{Reg} = \frac{SQ_{Reg}}{p-1}$	$F = \frac{QM_{Reg}}{QM_{Res}}$
Resíduos	$n - p$	$\mathbf{y}' \mathbf{y} - \hat{\beta}' \mathbf{X}' \mathbf{y}$	$QM_{Res} = \frac{SQ_{Res}}{n-p}$	
Total	$n - 1$	$\mathbf{y}' \mathbf{y} - \frac{\left(\sum_{i=1}^n y_i\right)^2}{n}$		

- Vale lembrar que n é o tamanho da amostra e $p = k + 1$ o número de parâmetros do modelo.

Análise de variância

- Podemos testar a significância do modelo ajustado com base no seguinte par de hipóteses:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0;$$

$$H_1 : \beta_j \neq 0 \text{ para pelo menos um } j.$$

- Sob a hipótese nula (não significância do modelo) a estatística F segue distribuição F -Snedecor, com $p - 1$ e $n - p$ graus de liberdade.
- Assim, fixado um nível de significância α , H_0 deve ser rejeitada se o valor da estatística F for maior que o quantil $1 - \alpha$ da distribuição $F_{p-1, n-p}$.

- O coeficiente de determinação, como anteriormente, fica definido por:

$$R^2 = 1 - \frac{SQ_{Res}}{SQ_{Total}} = \frac{SQ_{Reg}}{SQ_{Total}}, \quad (21)$$

que expressa a proporção da variabilidade original dos dados explicada pelo modelo de regressão.

- Uma propriedade de R^2 que o torna pouco apropriado para a comparação dos ajustes de diferentes modelos é que ele nunca decresce à medida que incluímos novas variáveis ao modelo.

Análise de variância

- Como alternativa ao R^2 podemos considerar o R^2 ajustado, definido por:

$$R_{Aj}^2 = 1 - \frac{SQ_{Res}/(n - p)}{SQ_{Total}/(n - 1)}. \quad (22)$$

- Como $SQ_{Total}/(n - 1)$ é fixo, então R_{Aj}^2 somente aumentará se houver redução do quadrado médio de resíduos.
- Diferentemente de R^2 , R_{Aj}^2 penaliza a inclusão de variáveis não importantes no modelo, permitindo comparar adequadamente modelos com diferentes complexidades (números de variáveis).

TH's e IC's para os parâmetros do modelo de regressão linear múltipla

- Primeiramente vamos considerar TH's e IC's para parâmetros individuais do modelo.
- Suponha que se deseja testar a significância de x_j no modelo. Partimos do seguinte par de hipóteses:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0. \quad (23)$$

- A estatística do teste é dada por:

$$t = \frac{\hat{\beta}_j}{ep(\hat{\beta}_j)}, \quad (24)$$

em que $ep(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{jj}^{-1}}$, sendo $(\mathbf{X}'\mathbf{X})_{jj}^{-1}$ o j - ésimo termo da diagonal de $(\mathbf{X}'\mathbf{X})^{-1}$ e $\hat{\sigma}^2 = QM_{Res}$.

TH's e IC's para os parâmetros do modelo de regressão linear múltipla

- Sob a hipótese nula a estatística t tem distribuição $t - Student$ com $n - p$ graus de liberdade.
- Assim, a hipótese H_0 deverá ser rejeitada, para um nível de significância α , se $|t| > |t_{n-p, \alpha/2}|$, em que $t_{n-p, \alpha/2}$ é o quantil $\alpha/2$ da distribuição $t - Student$ com $n - p$ graus de liberdade.
- Usando a distribuição t_{n-p} como referência, um intervalo de confiança $100(1 - \alpha)\%$ para β_j fica definido por:

$$\hat{\beta}_j \mp t_{n-p, \alpha/2} \sqrt{\hat{\sigma}^2 (\mathbf{X}'\mathbf{X})_{jj}^{-1}}. \quad (25)$$

- Para qualquer valor β_{j0} pertencente ao intervalo de confiança não se tem evidências, ao nível de significância α , que $\beta_j \neq \beta_{j0}$.

Intervalo de confiança para a resposta média e para uma predição

- Considere interesse em estimar a resposta média em um ponto $\mathbf{x}'_0 = (1, x_{01}, x_{02}, \dots, x_{0k})$, ou seja, $E(y|\mathbf{x}_0)$.
- A estimativa pontual é dada pelo valor ajustado pelo modelo em \mathbf{x}_0 :

$$\widehat{E(y|\mathbf{x}_0)} = \hat{y}_0 = \mathbf{x}'_0 \hat{\beta}. \quad (26)$$

- O estimador apresentado é não viciado para a real resposta média, com variância:

$$\text{Var}(\widehat{E(y|\mathbf{x}_0)}) = \sigma^2 \mathbf{x}'_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0. \quad (27)$$

Intervalo de confiança para a resposta média e para uma predição

- Um intervalo de confiança $100(1 - \alpha)\%$ para a resposta média em $\mathbf{x}'_0 = (1, x_{01}, x_{02}, \dots, x_{0k})$ é dado por:

$$\widehat{E(y|\mathbf{x}_0)} \mp t_{n-p, \alpha/2} \sqrt{\hat{\sigma}^2 \mathbf{x}'_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0}. \quad (28)$$

em que $\hat{\sigma}^2 = QM_{Res}$.

- Considere agora que se deseja prever a resposta em um ponto $\mathbf{x}'_0 = (1, x_{01}, x_{02}, \dots, x_{0k})$.
- A estimativa pontual, novamente, é dada pelo valor ajustado de y em \mathbf{x}'_0 :

$$\hat{y}_0 = \mathbf{x}'_0 \hat{\beta}. \quad (29)$$

Intervalo de confiança para a resposta média e para uma predição

- Neste caso, a variância de \hat{y}_0 fica dada por:

$$\text{Var}(\hat{y}_0) = \sigma^2 \left(1 + \mathbf{x}_0' (\mathbf{X}' \mathbf{X})^{-1} \mathbf{x}_0 \right). \quad (30)$$

- Um intervalo de confiança $100(1 - \alpha)\%$ para a predição de uma nova observação em \mathbf{x}_0 fica dada por:

$$\hat{y}_0 \mp t_{n-p, \alpha/2} \sqrt{\hat{\sigma}^2 \left(1 + \mathbf{x}_0' (\mathbf{X}' \mathbf{X})^{-1} \mathbf{x}_0 \right)}, \quad (31)$$

em que $\hat{\sigma}^2 = QM_{Res}$.

Inferência para vários parâmetros do modelo

- Em geral os estimadores dos parâmetros do modelo de RLM são correlacionados (a menos que as correspondentes variáveis sejam independentes);
- Avaliar a significância individual das variáveis e avaliar a significância conjunta das mesmas, neste caso, são coisas distintas.
- Em alguns casos temos interesse particular em analisar a significância conjunta de dois ou mais parâmetros, como no caso de modelos polinomiais e com variáveis indicadoras.
- Vamos abordar testes de hipóteses simultâneos para dois ou mais parâmetros do modelo usando o princípio da verossimilhança.

Inferência para vários parâmetros do modelo

- Considere o modelo de regressão linear múltipla:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \epsilon, \quad (32)$$

$\hat{\beta}' = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k)$ o vetor de estimativas de mínimos quadrados e $\hat{\sigma}^2 = SQ_{Res}/n$ a estimativa de máxima verossimilhança para σ^2 .

- O interesse aqui é testar uma hipótese do tipo $H_0 = \beta_1 = \beta_2 = \dots = \beta_q = 0$, $q \leq k$. Por simplicidade de notação, vamos considerar que a hipótese nula contemple os q primeiros parâmetros do modelo.

Inferência para vários parâmetros do modelo

- O modelo induzido pela hipótese nula é dado por:

$$\begin{aligned} y &= \beta_0 + 0x_1 + 0x_2 + \dots + 0x_q + \beta_{q+1}x_{q+1} + \dots + \beta_kx_k + \epsilon \\ &= \beta_0 + \beta_{q+1}x_{q+1} + \dots + \beta_kx_k + \epsilon \end{aligned} \quad (33)$$

- Vamos denotar por $\hat{\beta}'_0 = (\hat{\beta}'_0, 0, 0, \dots, \hat{\beta}'_{q+1}, \dots, \hat{\beta}'_k)$ o estimador de mínimos quadrados para o modelo restrito.

Inferência para vários parâmetros do modelo

- A verossimilhança para o modelo completo, avaliada nas estimativas de máxima verossimilhança, é dada por:

$$L = \left(2\pi \frac{SQ_{Res}}{n} \right)^{-n/2}, \quad (34)$$

em que SQ_{Res} é a soma de quadrados de resíduos do modelo.

- Para o modelo restrito a verossimilhança maximizada fica dada por:

$$L_0 = \left(2\pi \frac{SQ_{Res_0}}{n} \right)^{-n/2}, \quad (35)$$

em que SQ_{Res_0} é a soma de quadrados de resíduos para o modelo restrito (ajustado apenas com as $k - q$ variáveis não restritas a zero).

Inferência para vários parâmetros do modelo

- O teste da razão de verossimilhanças para testar H_0 baseia-se na estatística da razão de verossimilhanças:

$$\frac{L_0}{L} = \left(\frac{SQ_{Res_0}}{SQ_{Res}} \right)^{-n/2} = \left(\frac{SQ_{Res}}{SQ_{Res_0}} \right)^{n/2}. \quad (36)$$

- Sob a hipótese H_0 , assintoticamente:

$$\Lambda = -2 \ln \left(\frac{L_0}{L} \right) \sim \chi_q^2, \quad (37)$$

em que χ_q^2 denota a distribuição qui-quadrado com q graus de liberdade.

- Para um nível de significância α , H_0 será rejeitada se Λ superar o quantil $1 - \alpha$ da distribuição χ_q^2 .

Inferência para vários parâmetros do modelo

- No caso de modelos lineares, no entanto, temos um teste exato como alternativa ao teste assintótico baseado na distribuição qui-quadrado;
- Sob a hipótese nula, a estatística:

$$F_0 = \frac{(SQ_{Res_0} - SQ_{Res})/q}{SQ_{Res}/(n - p)} \quad (38)$$

tem distribuição F-Snedecor com q e $n - p$ graus de liberdade.

- Observe que F_0 baseia-se na variação da soma de quadrados de resíduos resultante da restrição aplicada a q parâmetros do modelo.
- A hipótese H_0 deverá ser rejeitada, ao nível de significância α , se F_0 superar o quantil $1 - \alpha$ da distribuição F-Snedecor com q e $n - p$ graus de liberdade.

Inferência para vários parâmetros do modelo

- A estatística F_0 pode ser calculada por:

$$F_0 = \frac{(\hat{\beta}_q - \beta_q^{(0)})' \mathbf{V}_{11}^{-1} (\hat{\beta}_q - \beta_q^{(0)})}{qQM_{Res}}, \quad (39)$$

em que $\hat{\beta}_q$ denota o vetor de q entradas de $\hat{\beta}$ referente aos parâmetros restritos e \mathbf{V}_{11} a matriz quadrada com as q entradas (linhas e colunas) de $(\mathbf{X}'\mathbf{X})^{-1}$.

- Repare que nesta representação $\beta_q^{(0)}$ representa o vetor postulado para os q parâmetros restritos sob H_0 (geralmente um vetor de zeros).

Inferência para vários parâmetros do modelo

- O teste da significância do modelo de regressão ($H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$) é um caso particular, em que a estatística F , apresentada no quadro da análise de variância, tem distribuição F-Snedecor com $p - 1$ e $n - p$ graus de liberdade sob H_0 .

Região de confiança

- Suponha interesse em estimar simultaneamente algum subconjunto de parâmetros do modelo.
- Seja β_q um subconjunto de elementos de β , contendo parâmetros sobre os quais se deseja inferir.
- Adicionalmente, seja $\hat{\beta}_q$ o vetor de estimadores de mínimos quadrados de β_q .
- Uma região de confiança $100(1 - \alpha)\%$ para os componentes de β_q é definido pelo conjunto de todos os vetores $\beta_q^{(0)}$ tais que:

$$F_0 = \frac{(\hat{\beta}_1 - \beta_1^{(0)})' \mathbf{V}_{11}^{-1} (\hat{\beta}_1 - \beta_1^{(0)})}{qQM_{Res}} \leq F_{q,n-p}(1 - \alpha) \quad (40)$$

em que $F_{q,n-p}(\alpha)$ é o quantil $1 - \alpha$ da distribuição F-Snedecor com q e $n - p$ graus de liberdade.

Testes de hipóteses para combinações lineares dos parâmetros

- De forma mais geral, podemos definir hipóteses lineares na forma:

$$H_0 : \mathbf{L}\boldsymbol{\beta} = \mathbf{c}, \quad (41)$$

em que \mathbf{L} é uma matriz de constantes de dimensão $q \times p$, de rank linha completo, e \mathbf{c} um vetor de constantes de dimensão q (ambos especificados).

- Neste caso, H_0 compreende q hipóteses lineares sobre os parâmetros do modelo, do tipo:

$$L_{11}\beta_0 + L_{12}\beta_1 + L_{13}\beta_2 + \dots + L_{1p}\beta_k = c_1$$

$$L_{21}\beta_0 + L_{22}\beta_1 + L_{23}\beta_2 + \dots + L_{2p}\beta_k = c_2$$

$$\vdots$$

$$L_{q1}\beta_0 + L_{q2}\beta_1 + L_{q3}\beta_2 + \dots + L_{qp}\beta_k = c_q$$

Testes de hipóteses para combinações lineares dos parâmetros

- Sob a hipótese H_0 a estatística:

$$F = \frac{(L\beta - c)'[L(X'X)^{-1}L']^{-1}(L\beta - c)}{qQM_{Res}} \quad (42)$$

tem distribuição F-Snedecor com q e $n - p$ graus de liberdade.

- Assim, a hipótese nula será rejeitada, ao nível de significância α , se o valor calculado da estatística F exceder o quantil $1 - \alpha$ da distribuição F-Snedecor com q e $n - p$ graus de liberdade.

Intervalos de confiança para combinações lineares dos parâmetros

- Seja $\mathbf{l}' = (l_0, l_1, l_2, \dots, l_p)$ um vetor de constantes e considere interesse em estimar $\theta = \mathbf{l}'\boldsymbol{\beta}$.
- A estimativa pontual de $\mathbf{l}'\boldsymbol{\beta}$ é dada por $\mathbf{l}'\hat{\boldsymbol{\beta}}$.
- Um intervalo de confiança $100(1 - \alpha)\%$ para $\mathbf{l}'\boldsymbol{\beta}$ tem limites:

$$\mathbf{l}'\hat{\boldsymbol{\beta}} \mp t_{n-p, \alpha/2} \sqrt{\hat{\sigma}^2 \mathbf{l}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{l}}. \quad (43)$$

Regressão com coeficientes padronizados

- Na análise de RLM, a comparação das magnitudes dos $\hat{\beta}'_j$ s em sempre é possível devido ao impacto das diferentes unidades de medidas dos x'_j s.
- Caso seja desejado que tais estimativas sejam comparáveis, pode-se padronizar cada uma das variáveis de forma que as variáveis resultantes tenham uma mesma escala.
- Uma alternativa de padronização consiste em 'normalizar' cada uma das variáveis, aplicando:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, \quad i = 1, 2, \dots, n; j = 1, 2, \dots, k, \quad (44)$$

e

$$y_i^* = \frac{y_i - \bar{y}}{s_y}, \quad i = 1, 2, \dots, n, \quad (45)$$

Regressão com coeficientes padronizados

- Neste caso, \bar{x}_j e s_j são a média e o desvio padrão amostrais de x_j e \bar{y} e s_y a média e desvio padrão amostrais de y .
- Usando as variáveis normalizadas, o modelo de regressão linear múltipla fica definido por:

$$y_i^* = b_1 z_{i1} + b_2 z_{i2} + \dots + b_k z_{ik} + \epsilon_i, \quad i = 1, 2, \dots, n. \quad (46)$$

- A análise segue então da maneira usual de forma que o estimador de mínimos quadrados de \mathbf{b} fica dado por:

$$\hat{\mathbf{b}} = (\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{y}. \quad (47)$$

Regressão com coeficientes padronizados

- Ao centrar as variáveis, o intercepto do modelo é deslocado para zero.
- As interpretações dos parâmetros do modelo devem ser feitas em termos dos valores padronizados das variáveis originais.